Les données de panel

Guide complet : notions, modèles (MCO empilés, effets fixes, effets aléatoires, modèles mixtes, panels dynamiques), tests, illustrations et exemples chiffrés

Christian TOSSE — M2 Mathématiques des Données

Novembre 2026

Table des matières

Comment lire ce guide **3**

1 Qu'est-ce qu'un panel ? **4**
1.1 Définition . . . 4
1.2 Vocabulaire à connaître . . . 4
1.3 Deux formats de stockage : long et large . . . 5
1.4 Pourquoi utiliser un panel ? Les cinq avantages . . . 5

2 Visualiser un panel **6**

3 Deux sources de variation : « entre » et « dans » **8**
3.1 L'idée . . . 8
3.2 Les formules . . . 8
3.3 Petit exemple chiffré . . . 8

4 Le problème central : l'hétérogénéité non observée **10**
4.1 Le modèle qui décrit la réalité . . . 10
4.2 Le biais de variable omise . . . 10

5 Le modèle des MCO empilés (*pooled OLS*) **12**
5.1 Modèle et hypothèses . . . 12
5.2 Exemple . . . 12

6 L'estimateur « between » (inter-individuel) **12**

7 Le modèle à effets fixes **13**
7.1 L'idée . . . 13
7.2 Méthode 1 : les variables indicatrices (LSDV) . . . 13
7.3 Méthode 2 : la transformation « within » (centrage individuel) . . . 13
7.4 Méthode 3 : les différences premières . . . 14
7.5 Comparaison chiffrée des estimateurs . . . 14
7.6 Les effets individuels estimés . . . 15
7.7 Tester la présence d'effets individuels : le test de Fisher . . . 15
7.8 Ce que les effets fixes ne savent pas faire . . . 15

8 Effets temporels et effets fixes à deux dimensions **16**
8.1 Le modèle . . . 16
8.2 Le lien avec les doubles différences (*difference-in-differences*) . . . 16

9 Le modèle à effets aléatoires **18**
9.1 L'idée . . . 18
9.2 La structure de corrélation et l'ICC . . . 18
9.3 L'estimation : MCG par quasi-centrage . . . 18
9.4 Exemples : un cas où les effets aléatoires conviennent, un cas où ils échouent . . . 19

10 Choisir entre les modèles : les tests **20**
10.1 Trois tests, trois questions . . . 20
10.2 Le test de Hausman en détail . . . 20
10.3 L'approche de Mundlak (effets aléatoires corrélés) . . . 20

11 Les modèles mixtes (modèles multiniveaux) **22**
11.1 Même famille que les effets aléatoires, vue plus générale . . . 22
11.2 Intercept aléatoire . . . 22
11.3 Pente aléatoire . . . 22
11.4 Exemple réel : privation de sommeil (`sleepstudy`) . . . 22
11.5 Le rétrécissement (*shrinkage*) . . . 24
11.6 Niveaux emboîtés et autres extensions . . . 24

12 Inférence robuste et diagnostics **25**
12.1 Pourquoi les écarts-types usuels sont souvent faux . . . 25
12.2 La solution standard : les écarts-types robustes par grappe (*clustered*) . . . 25
12.3 Les tests de diagnostic à connaître . . . 25

13 Panels dynamiques **26**
13.1 Le modèle . . . 26
13.2 Le biais de Nickell . . . 26
13.3 Les solutions : variables instrumentales et GMM . . . 26

14 Autres situations à connaître **28**

15 Synthèse **29**
15.1 Les modèles en un tableau . . . 29
15.2 La démarche en huit étapes . . . 29
15.3 Principales fonctions R . . . 29
15.4 Glossaire . . . 30

Comment lire ce guide

Ce guide explique **les données de panel de A à Z**, pour quelqu'un qui débute. Chaque notion suit le même déroulé :

1. l'**intuition**, avec un exemple concret ;
2. la **formule** ;
3. une **figure** ;
4. un **petit exemple chiffré** et son résultat.

Deux exemples servent de fil rouge :

- **les hôpitaux (données simulées)**. Pour 6 hôpitaux (ou 50), suivis pendant 8 ans, on observe le **taux de réadmission** y (en %) et le **nombre d'infirmiers pour 10 lits** x. Comme les données sont simulées, **on connaît la vérité** : un infirmier de plus pour 10 lits fait baisser la réadmission de **0,8 point**. On peut donc vérifier quelles méthodes retrouvent cette valeur. Le piège est le suivant : les hôpitaux qui reçoivent les patients les plus graves ont à la fois **plus de réadmissions** et **plus d'infirmiers**. Cette gravité n'est pas mesurée ;
- **la consommation de cigarettes (données réelles, `Cigar`)** : 46 États américains, de 1963 à 1992.

Les encadrés bleus résument l'essentiel ; les encadrés orange signalent les pièges. La section 15 donne un résumé, une méthode de choix et un glossaire.

Notations. $i = 1, \dots, N$ désigne l'individu, $t = 1, \dots, T$ la date, y_{it} la variable expliquée et x_{it} la (ou les) variable(s) explicative(s). α_i est l'effet propre à l'individu i et λ_t l'effet propre à la date t. Une barre désigne une moyenne : $\bar{y}_i = \frac{1}{T}\sum_t y_{it}$ (moyenne de l'individu i sur le temps) et $\bar{y} = \frac{1}{NT}\sum_{i,t} y_{it}$ (moyenne générale).

1 Qu'est-ce qu'un panel ?

1.1 Définition

Des **données de panel** (ou **données longitudinales**) sont des observations sur **plusieurs individus**, chacun suivi à **plusieurs dates**. L'« individu » peut être une personne, un hôpital, une entreprise, une région ou un pays.

Un panel combine les deux types de données déjà rencontrés :

Type	Individus	Dates	Une ligne =	Exemple
Coupe transversale	plusieurs (N)	une	un individu	une enquête auprès de 5 000 patients en 2024
Série temporelle	un	plusieurs (T)	une date	les décès mensuels au Royaume-Uni (ldeaths)
Panel	plusieurs (N)	plusieurs (T)	**un couple (individu, date)**	réadmissions de 50 hôpitaux, de 2015 à 2022

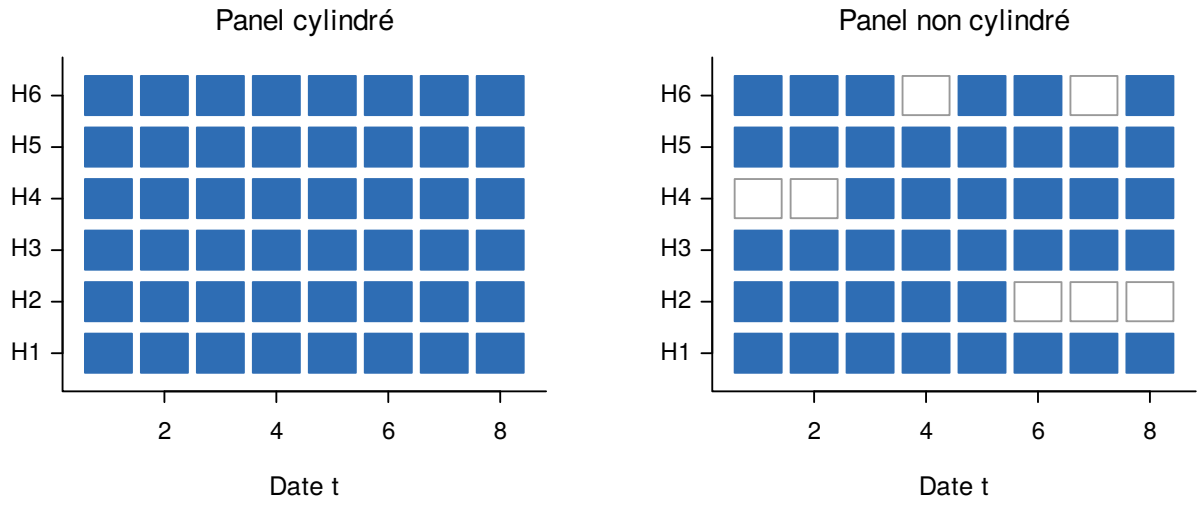


Figure 1: Un panel vu comme une grille individus × dates. Gauche : panel cylindré (toutes les cases sont observées). Droite : panel non cylindré (des cases manquent : individus entrés en cours de route, perdus de vue, données manquantes).

1.2 Vocabulaire à connaître

- **Panel cylindré** (*balanced*) : chaque individu est observé à chaque date, soit $N \times T$ lignes. Un **panel non cylindré** (*unbalanced*) a des trous. La plupart des méthodes fonctionnent quand même, mais il faut se demander **pourquoi** des données manquent : c'est la question de l'**attrition**.
- **Micro-panel** : N grand, T petit (des milliers de patients suivis 3 ans). **Macro-panel** : N petit ou moyen, T grand (30 pays suivis 40 ans). Ce n'est pas qu'une question de taille : avec T grand, les questions de séries temporelles (stationnarité, autocorrélation) redeviennent centrales.

- **Variable qui varie dans le temps** : un salaire, un nombre d'infirmiers. **Variable fixe dans le temps** : le sexe, la région, l'année de création d'un hôpital. Cette distinction est capitale pour les effets fixes (section 7).

1.3 Deux formats de stockage : long et large

Tableau 2: Format LONG : une ligne par couple (hôpital, année). C'est le format attendu par les logiciels de panel.

	hopital	annee	x	y
1	H1	1	4.84	6.64
2	H1	2	5.01	6.83
3	H1	3	4.90	5.51
9	H2	1	7.23	7.32
10	H2	2	6.41	7.58
11	H2	3	6.43	7.10

Tableau 3: Format LARGE : une ligne par hôpital, une colonne par année (ici pour la seule variable y).

hopital	y_an1	y_an2	y_an3
H1	6.64	6.83	5.51
H2	7.32	7.58	7.10

Le **format long** est celui qu'utilisent les fonctions de panel de R (`plm`, `lme4`). On y déclare deux colonnes d'**index** : l'identifiant de l'individu et la date. Le **format large** sert surtout à l'affichage. On passe de l'un à l'autre avec `reshape()` ou `tidyr::pivot_longer()` / `pivot_wider()`.

1.4 Pourquoi utiliser un panel ? Les cinq avantages

1. **Contrôler l'hétérogénéité non observée.** On peut neutraliser les différences permanentes entre individus, même quand elles ne sont pas mesurées (gravité des patients, culture d'un pays). C'est l'avantage principal (section 4).
2. **Plus d'information** : $N \times T$ observations, plus de variabilité, moins de colinéarité entre variables.
3. **Étudier la dynamique** : comment les individus changent, ce qui persiste d'une année sur l'autre.
4. **Distinguer deux questions** qu'une coupe transversale confond : « les hôpitaux qui ont plus d'infirmiers ont-ils moins de réadmissions ? » (comparaison **entre** hôpitaux) et « quand **un même hôpital** recrute, ses réadmissions baissent-elles ? » (comparaison **dans** le temps).
5. **Évaluer des politiques publiques** : comparer l'évolution des individus touchés par une mesure à celle des autres (doubles différences, section 8).

2 Visualiser un panel

Avant tout modèle, il faut **regarder** les données. Trois graphiques sont indispensables.

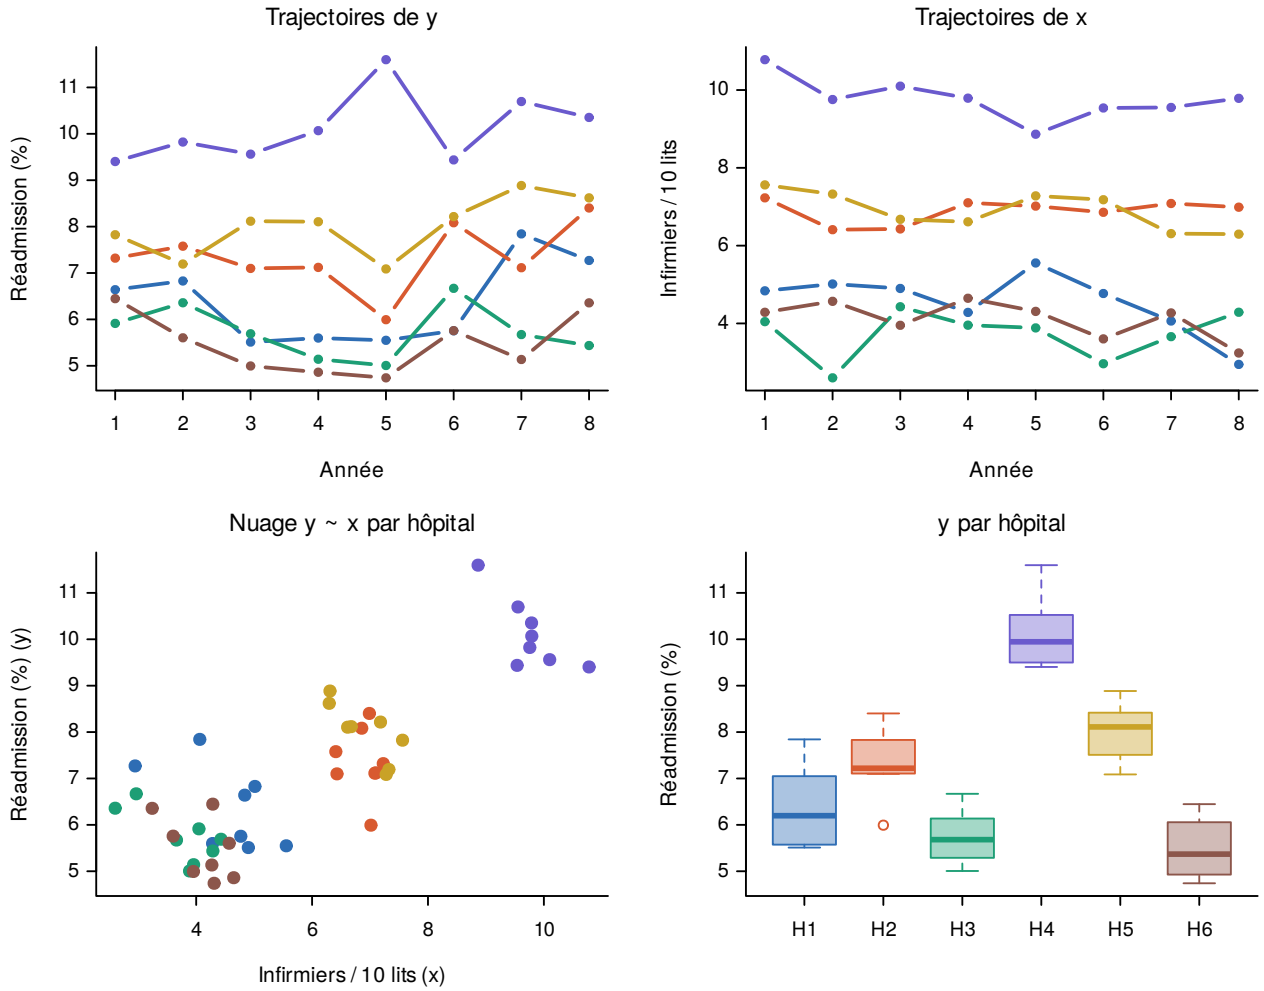


Figure 2: Données hôpitaux (6 hôpitaux, 8 ans). En haut : trajectoires individuelles (graphique « spaghetti ») de y et de x. En bas : nuage y en fonction de x, coloré par hôpital, et distribution de y par hôpital.

Lecture.

- Les trajectoires de y sont **décalées en hauteur** : chaque hôpital a son propre niveau moyen de réadmission. C'est l'**hétérogénéité individuelle**.
- Le nuage de points montre des **paquets de couleur** bien séparés. **Entre** les paquets, la tendance monte : les hôpitaux qui ont plus d'infirmiers ont plus de réadmissions. Mais **dans** chaque paquet, la tendance descend. Cette contradiction apparente est le cœur du sujet (section 4).

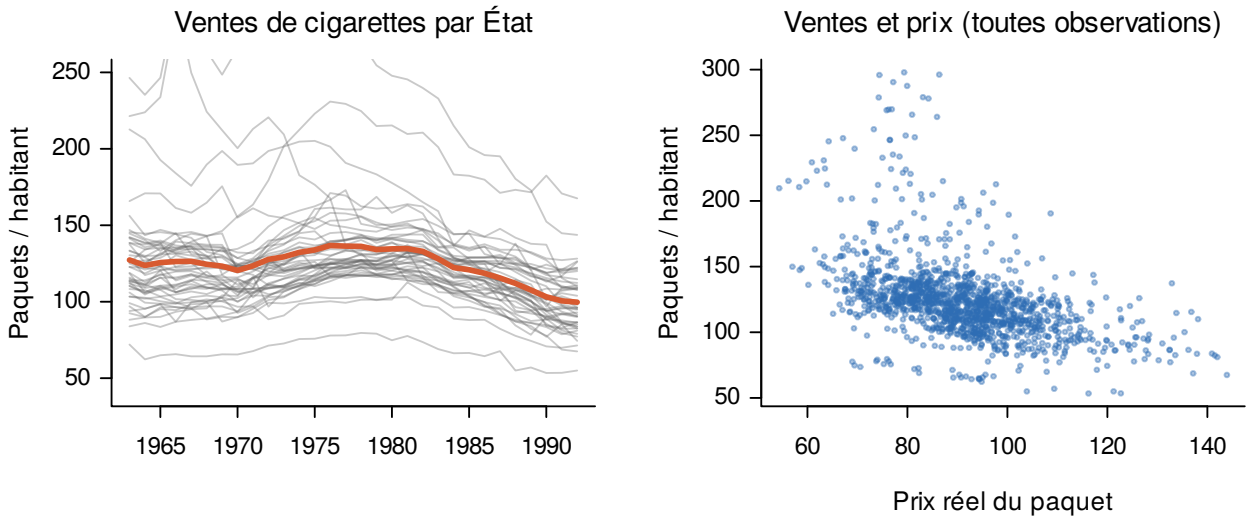


Figure 3: Données réelles Cigar : ventes de cigarettes (paquets par habitant) de 46 États, 1963-1992. Trajectoires (gris) et moyenne nationale (orange). Les États diffèrent fortement de niveau, mais partagent une évolution commune (hausse puis forte baisse après 1980).

3 Deux sources de variation : « entre » et « dans »

3.1 L'idée

Dans un panel, une variable varie de **deux façons** :

- **entre les individus** (*between*) : l'hôpital H5 a en moyenne plus d'infirmiers que l'hôpital H2. C'est une différence **permanente** ;
- **dans le temps, pour un même individu** (*within*) : l'hôpital H5 a plus d'infirmiers en 2020 qu'en 2019. C'est une variation **autour de sa propre moyenne**.

3.2 Les formules

Toute observation se décompose en trois morceaux :

$$x_{it} = \underbrace{\bar{x}}_{\text{moyenne générale}} + \underbrace{(\bar{x}_i - \bar{x})}_{\text{écart « entre »}} + \underbrace{(x_{it} - \bar{x}_i)}_{\text{écart « dans »}} .$$

La variabilité totale se partage exactement entre ces deux sources :

$$\underbrace{\sum_{i,t}(x_{it} - \bar{x})^2}_{\text{totale}} = \underbrace{T\sum_{i}(\bar{x}_i - \bar{x})^2}_{\text{inter-individuelle (between)}} + \underbrace{\sum_{i,t}(x_{it} - \bar{x}_i)^2}_{\text{intra-individuelle (within)}} .$$

3.3 Petit exemple chiffré

Tableau 4: Décomposition de x pour 3 hôpitaux observés 3 ans : x = moyenne générale + écart « entre » + écart « dans ».

	hopital	annee	x	moy_hop	moy_gen	ecart_entre	ecart_dans
1	H1	1	4.84	4.92	5.1	-0.18	-0.08
2	H1	2	5.01	4.92	5.1	-0.18	0.10
3	H1	3	4.90	4.92	5.1	-0.18	-0.02
9	H2	1	7.23	6.69	5.1	1.59	0.54
10	H2	2	6.41	6.69	5.1	1.59	-0.28
11	H2	3	6.43	6.69	5.1	1.59	-0.26
17	H3	1	4.05	3.69	5.1	-1.41	0.35
18	H3	2	2.60	3.69	5.1	-1.41	-1.09
19	H3	3	4.43	3.69	5.1	-1.41	0.74

Tableau 5: Données hôpitaux (6 × 8) : sommes de carrés totales, entre et dans, et part de la variabilité due au « dans ».

	totale	entre	dans	part_dans
x (infirmiers)	226.664	213.431	13.233	0.058
y (réadmission)	140.896	119.487	21.410	0.152

Lecture. Pour x, seulement 6 % de la variabilité vient de changements **dans** le temps ; le reste vient des différences **entre** hôpitaux. C'est fréquent : les individus diffèrent beaucoup plus entre eux qu'ils ne changent d'une année sur l'autre. Les **effets fixes n'utilisent que la partie « dans »**. Cela explique pourquoi leurs estimations sont parfois imprécises : on se prive de la variabilité « entre », à la fois la plus abondante et la plus contaminée.

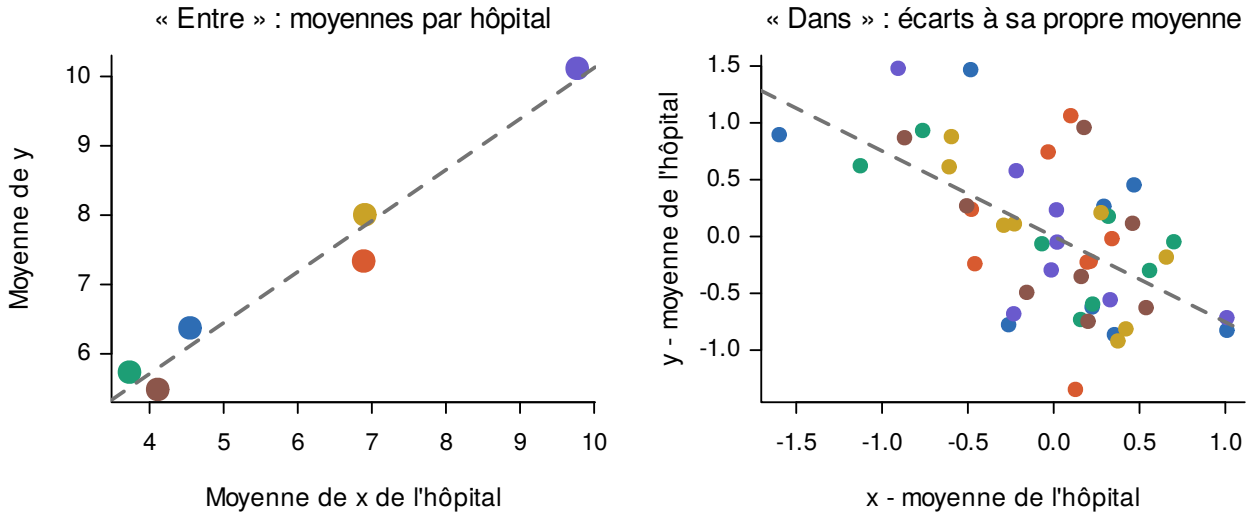


Figure 4: Gauche : variation « entre » (chaque point est la moyenne d'un hôpital). Droite : variation « dans » (chaque hôpital est recentré sur sa propre moyenne). Les deux nuages racontent des histoires opposées.

4 Le problème central : l'hétérogénéité non observée

4.1 Le modèle qui décrit la réalité

On suppose que la réalité s'écrit :

$$y_{it} = \beta\, x_{it} + \alpha_i + \varepsilon_{it}.$$

- β est **l'effet qu'on cherche** (l'effet causal d'un infirmier de plus sur la réadmission) ;
- α_i est l'**effet individuel** : tout ce qui est **propre à l'hôpital et ne change pas dans le temps** (gravité de ses patients, quartier, réputation, équipement). On **ne l'observe pas** ;
- ε_{it} est le bruit, aléatoire et imprévisible.

4.2 Le biais de variable omise

Si on ignore α_i et qu'on régresse simplement y sur x, l'effet individuel finit dans l'erreur. Si α_i est **corrélé à** x_{it} (les hôpitaux graves recrutent plus), la régression attribue à x une partie de l'effet de α_i. L'estimateur est alors **biaisé**, même avec une infinité de données :

$$\operatorname{plim} \hat{\beta}_{\text{MCO}} = \beta + \frac{\operatorname{Cov}(x_{it}, \alpha_i)}{\operatorname{Var}(x_{it})}.$$

Ici, $\operatorname{Cov}(x, \alpha) > 0$ (plus d'infirmiers là où les patients sont graves) et $\beta < 0$. Le biais est positif et peut même **inverser le signe** : on conclurait que les infirmiers augmentent les réadmissions.

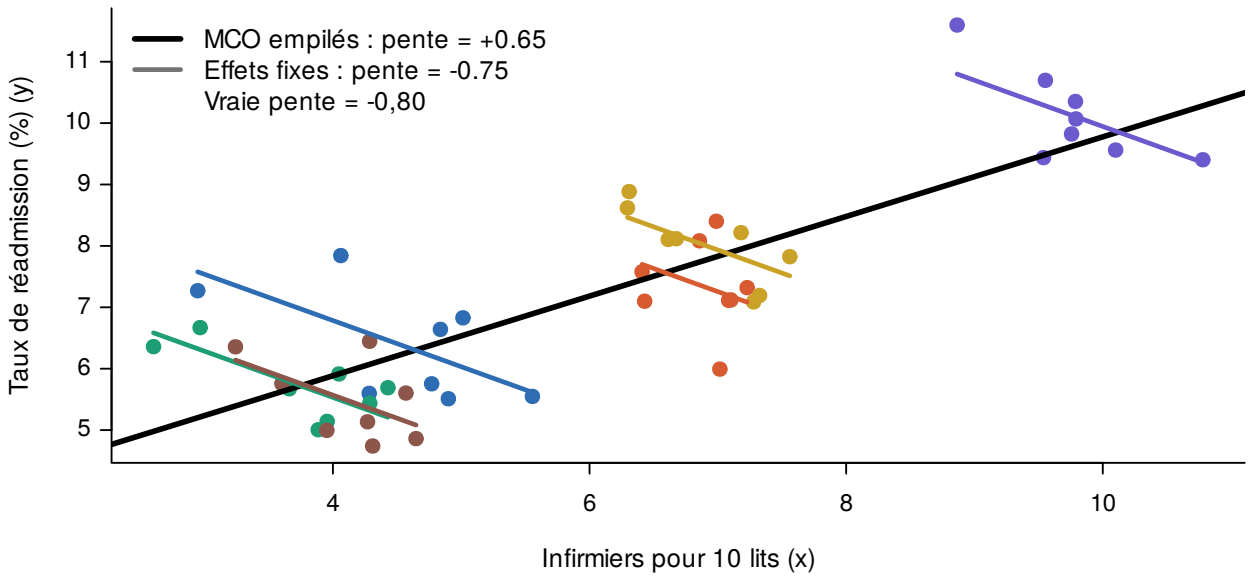


Figure 5: Le paradoxe (paradoxe de Simpson) : la droite des MCO empilés (noire) monte, alors que dans chaque hôpital la relation descend (droites colorées, de pente commune estimée par les effets fixes). La vraie pente est -0,8.

À retenir

Le panel résout ce problème parce qu'il observe chaque individu plusieurs fois. On peut ainsi **comparer chaque hôpital à lui-même**. Tout ce qui est fixe chez lui (α_i, mesuré ou non) disparaît de la comparaison. C'est l'idée des **effets fixes**.

5 Le modèle des MCO empilés (*pooled OLS*)

5.1 Modèle et hypothèses

On empile toutes les lignes et on fait une régression ordinaire, comme si les $N \times T$ observations étaient indépendantes :

$$y_{it} = \beta_0 + \beta_1 x_{it} + u_{it}, \qquad u_{it} = \alpha_i + \varepsilon_{it}.$$

L'estimateur n'est **sans biais** que si l'effet individuel α_i (caché dans l'erreur u_{it}) est **non corrélé** avec x_{it}. Même dans ce cas, deux problèmes demeurent :

- les erreurs d'un même individu sont **corrélées entre elles**, puisqu'elles partagent le même α_i : les écarts-types usuels sont **faux**, et il faut des écarts-types **robustes par grappe** (section 12) ;
- on gaspille de l'information sur la structure des données.

5.2 Exemple

Tableau 6: MCO empilés sur 50 hôpitaux × 8 ans. Coefficient de x (vraie valeur : -0,8).

	Estimate	Std. Error	t value	Pr(>|t|)
Écart-type usuel	0.673	0.024	28.384	0
Écart-type robuste par grappe	0.673	0.023	29.818	0

Lecture. Le coefficient vaut **0.67** au lieu de $-0{,}8$. Il est **biaisé**, et du mauvais signe. Les deux écarts-types sont petits et très proches : ici, le problème n'est pas la précision mais le biais. Un estimateur très précis autour d'une mauvaise valeur reste faux, et **aucun réglage des écarts-types ne répare un estimateur biaisé**. Les écarts-types par grappe deviennent cruciaux quand les erreurs sont autocorrélées (section 12).

6 L'estimateur « between » (inter-individuel)

On régresse les **moyennes individuelles** les unes sur les autres : $\bar{y}_i = \beta_0 + \beta_1 \bar{x}_i + \bar{u}_i$. On n'utilise ainsi que la variation **entre** individus. Cet estimateur souffre du même biais que les MCO empilés si α_i est corrélé à x, avec seulement N observations. Il sert surtout **de brique** : l'estimateur à effets aléatoires est une moyenne pondérée de l'estimateur between et de l'estimateur within (section 9).

Sur les 50 hôpitaux, l'estimateur between donne **0.77** : encore plus biaisé, puisqu'il n'utilise **que** la variation contaminée par la gravité.

7 Le modèle à effets fixes

7.1 L'idée

On donne à **chaque individu sa propre constante** α_i, qu'on estime ou qu'on élimine. Le modèle est

$$y_{it} = \alpha_i + \beta\, x_{it} + \varepsilon_{it}.$$

Ici, α_i peut être **corrélé** avec x_{it} : c'est tout l'intérêt de la méthode. On ne fait aucune hypothèse sur le lien entre l'effet individuel et les variables explicatives. β est estimé **uniquement à partir des variations dans le temps de chaque individu**.

Il existe trois façons équivalentes (ou presque) de l'estimer.

7.2 Méthode 1 : les variables indicatrices (LSDV)

On ajoute une **indicatrice par individu** dans une régression ordinaire (*Least Squares Dummy Variables*) :

$$y_{it} = \beta x_{it} + \alpha_1 D_{1,it} + \alpha_2 D_{2,it} + \cdots + \alpha_N D_{N,it} + \varepsilon_{it}, \qquad D_{j,it} = \mathbb{1}(i = j).$$

C'est simple et parlant, car on obtient directement une estimation de chaque α_i. Mais il faut estimer N constantes, ce qui devient lourd quand N est grand.

7.3 Méthode 2 : la transformation « within » (centrage individuel)

On fait la moyenne du modèle dans le temps pour chaque individu, $\bar{y}_i = \alpha_i + \beta\bar{x}_i + \bar{\varepsilon}_i$, puis on la **soustrait** au modèle :

$$\underbrace{y_{it} - \bar{y}_i}_{\tilde{y}_{it}} = \beta\, \underbrace{(x_{it} - \bar{x}_i)}_{\tilde{x}_{it}} + (\varepsilon_{it} - \bar{\varepsilon}_i).$$

L'effet α_i a disparu, car il est constant dans le temps, donc égal à sa moyenne. On régresse alors $\tilde{y}$ sur $\tilde{x}$ par MCO :

$$\hat{\beta}_{\text{FE}} = \frac{\sum_{i,t} \tilde{x}_{it}\tilde{y}_{it}}{\sum_{i,t} \tilde{x}_{it}^2}.$$

On obtient **exactement** le même $\hat{\beta}$ qu'avec les indicatrices. Il faut seulement corriger les degrés de liberté, en retirant les N moyennes estimées : $NT - N - K$.

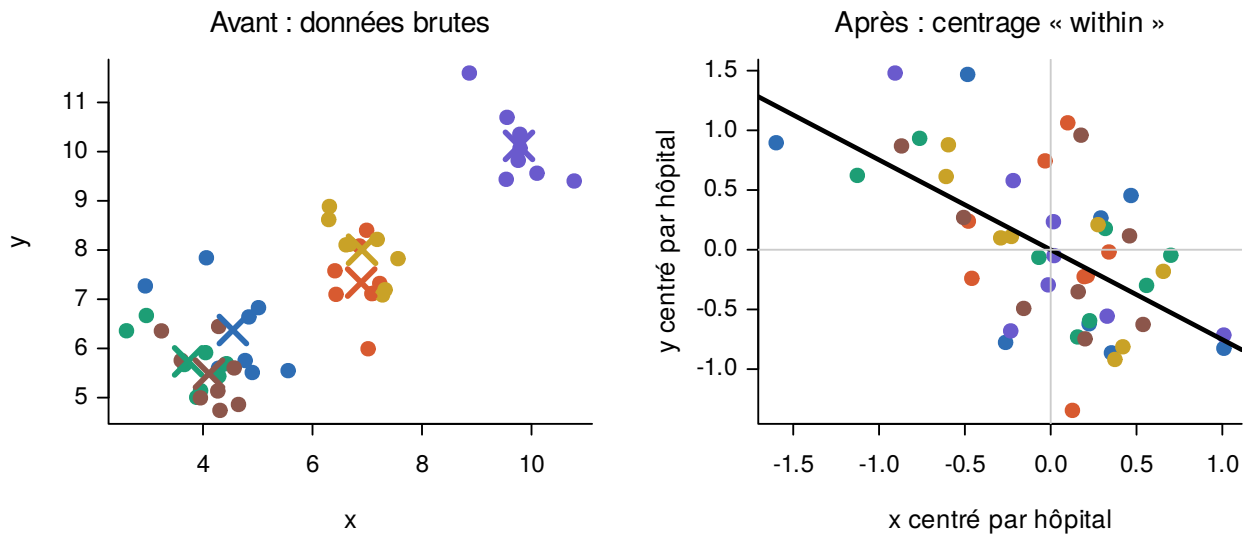


Figure 6: La transformation within en image. Gauche : données brutes (paquets séparés, pente globale trompeuse). Droite : après centrage de chaque hôpital sur sa propre moyenne, les paquets se superposent et la vraie pente apparaît.

Sur la figure de gauche, les croix marquent la moyenne de chaque hôpital. Le centrage déplace chaque paquet pour placer sa croix à l'origine.

7.4 Méthode 3 : les différences premières

On soustrait au modèle de l'année t celui de l'année $t-1$:

$$y_{it} - y_{i,t-1} = \beta(x_{it} - x_{i,t-1}) + (\varepsilon_{it} - \varepsilon_{i,t-1}).$$

Là encore, α_i **disparaît**. Avec $T = 2$, on obtient exactement le même résultat que le within. Avec $T > 2$, les deux méthodes diffèrent légèrement : le within est plus efficace si les ε_{it} sont indépendants, les différences premières si les ε_{it} ressemblent à une marche aléatoire.

7.5 Comparaison chiffrée des estimateurs

Tableau 7: Coefficient de x sur les 50 hôpitaux × 8 ans, selon l'estimateur. La vraie valeur est -0,8.

	coef_x	ecart_type
MCO empilés	0.673	0.024
Between	0.771	0.027
Effets fixes (within)	-0.854	0.045
Effets fixes (indicatrices LSDV)	-0.854	0.045
Différences premières	-0.838	0.045

Lecture. Les trois versions des effets fixes retrouvent la vraie valeur (environ $-0{,}8$), avec des écarts-types presque identiques. Les MCO empilés et le between, qui utilisent la variation « entre » contaminée par la gravité, se trompent de signe.

7.6 Les effets individuels estimés

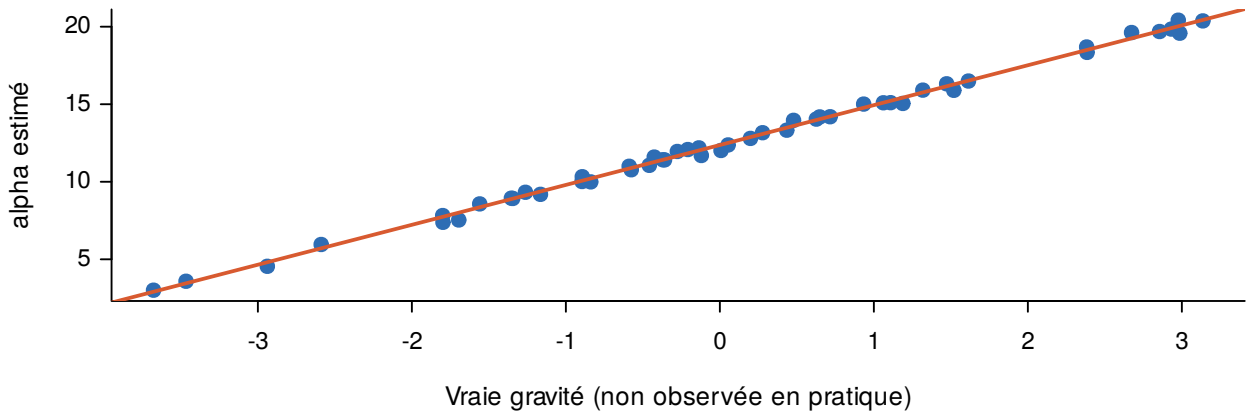


Figure 7: Effets fixes estimés (LSDV, 50 hôpitaux) en fonction de la vraie gravité simulée. Les alpha estimés capturent bien l'hétérogénéité cachée.

Les $\hat{\alpha}_i$ servent à **comparer les individus une fois l'effet de x retiré**, par exemple pour classer les hôpitaux par réadmission « ajustée ». Attention : avec T petit, chaque $\hat{\alpha}_i$ est estimé sur peu d'observations, donc de façon imprécise.

7.7 Tester la présence d'effets individuels : le test de Fisher

$H_0 : \alpha_1 = \alpha_2 = \cdots = \alpha_N$ (une seule constante, donc les MCO empilés suffisent).

$$F = \frac{(SCR_{\text{empilés}} - SCR_{\text{FE}})/(N-1)}{SCR_{\text{FE}}/(NT - N - K)} \sim F(N-1,\, NT - N - K).$$

Sur les hôpitaux, $F = 30.9$ et $\text{p} < 10^{-10}$: on rejette H_0. Les hôpitaux ont bien des niveaux propres, et les MCO empilés ne conviennent pas.

7.8 Ce que les effets fixes ne savent pas faire

Attention

1. **Pas d'effet des variables fixes dans le temps.** Le sexe, la région ou le statut public/privé d'un hôpital disparaissent avec α_i, car ils sont absorbés par l'effet individuel. On ne peut pas estimer leur effet par effets fixes.
2. **Peu de variation « dans » donne des estimations imprécises.** Si x change à peine dans le temps, $\hat{\beta}_{\text{FE}}$ a un grand écart-type.
3. **Les effets fixes ne retirent que ce qui est fixe.** Un facteur caché qui **varie dans le temps** (une épidémie locale, un changement de direction) biaise toujours l'estimation.
4. **Les erreurs de mesure sont amplifiées.** Le centrage retire la partie stable de x ; il reste surtout du « bruit » de mesure, ce qui tire $\hat{\beta}$ vers 0.

8 Effets temporels et effets fixes à deux dimensions

8.1 Le modèle

Certains chocs touchent **tous les individus la même année** : une crise économique, une épidémie nationale, une nouvelle loi, un changement de méthode de codage. On les capte par un effet propre à chaque date, λ_t :

$$y_{it} = \alpha_i + \lambda_t + \beta x_{it} + \varepsilon_{it}.$$

On l'estime en ajoutant des indicatrices d'année, ou par un **double centrage** :

$$\tilde{y}_{it} = y_{it} - \bar{y}_i - \bar{y}_t + \bar{y} \quad \text{(et de même pour } x\text{)}.$$

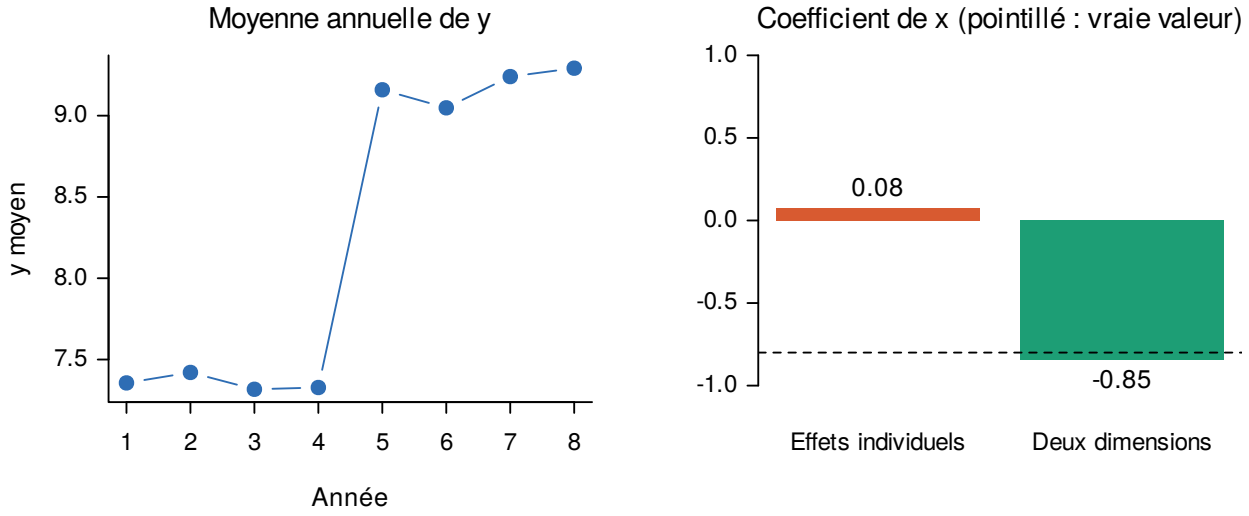


Figure 8: Simulation : en plus des effets hôpitaux, un choc national touche toutes les réadmissions en année 5 (nouveau codage). Gauche : la moyenne annuelle montre le choc. Droite : estimation de beta avec effets individuels seuls ou à deux dimensions. Le choc est corrélé à x (recrutement national cette année-là), ce qui biaise le modèle à une dimension.

8.2 Le lien avec les doubles différences (*difference-in-differences*)

Supposons qu'une politique s'applique à un groupe d'individus à partir d'une date t_0, et notons $D_{it} = 1$ si l'individu est traité et $t \geq t_0$. Le modèle à deux dimensions

$$y_{it} = \alpha_i + \lambda_t + \delta D_{it} + \varepsilon_{it}$$

estime δ, **l'effet de la politique**. Il compare l'évolution des traités à celle des non-traités, ce qui élimine les différences permanentes entre groupes (via α_i) et les chocs communs (via λ_t).

L'hypothèse clé est celle des **tendances parallèles** : sans la politique, les deux groupes auraient évolué de la même façon. On la vérifie en regardant les années **avant** la politique.

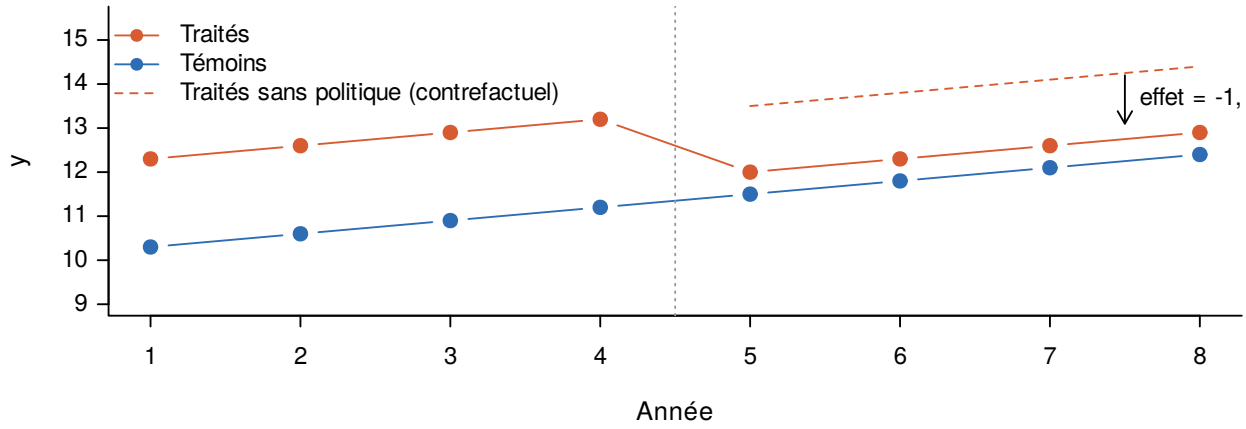


Figure 9: Doubles différences : la politique (année 5) touche le groupe traité. L'effet estimé est l'écart entre l'évolution observée des traités et leur évolution contrefactuelle (pointillés), parallèle à celle des témoins.

9 Le modèle à effets aléatoires

9.1 L'idée

On considère cette fois l'effet individuel comme une **variable aléatoire**, tirée dans une loi :

$$y_{it} = \beta_0 + \beta x_{it} + \underbrace{u_i + \varepsilon_{it}}_{\text{erreur composée}}, \qquad u_i \sim (0, \sigma_u^2),\ \varepsilon_{it} \sim (0, \sigma_\varepsilon^2).$$

Les individus observés sont vus comme un **échantillon** tiré d'une population plus large, par exemple 50 hôpitaux tirés parmi tous les hôpitaux du pays. Au lieu d'estimer 50 constantes, on estime **une seule variance** σ_u^2.

Hypothèse cruciale : u_i est **non corrélé** avec x_{it}. C'est exactement l'hypothèse qui est **fausse** dans l'exemple des hôpitaux.

9.2 La structure de corrélation et l'ICC

Deux observations d'un même individu partagent le même u_i, donc elles sont corrélées :

$$\text{Corr}(u_i + \varepsilon_{it},\, u_i + \varepsilon_{is}) = \rho = \frac{\sigma_u^2}{\sigma_u^2 + \sigma_\varepsilon^2} \quad (t \neq s).$$

On appelle ρ le **coefficient de corrélation intra-classe (ICC)**. C'est la **part de la variance qui est due aux différences entre individus**. Par exemple, $\rho = 0{,}7$ signifie que 70 % des écarts de réadmission viennent de différences permanentes entre hôpitaux.

9.3 L'estimation : MCG par quasi-centrage

On utilise les moindres carrés généralisés (MCG), qui reviennent à un **centrage partiel** :

$$y_{it} - \theta \bar{y}_i = \beta_0(1-\theta) + \beta(x_{it} - \theta \bar{x}_i) + \text{erreur}, \qquad \theta = 1 - \sqrt{\frac{\sigma_\varepsilon^2}{\sigma_\varepsilon^2 + T\sigma_u^2}}.$$

Le paramètre θ règle le compromis entre les deux estimateurs déjà vus :

- si $\theta = 0$, on obtient les **MCO empilés** (aucun centrage) ;
- si $\theta = 1$, on obtient les **effets fixes** (centrage complet) ;
- plus T est grand et plus l'ICC est élevé, plus θ se rapproche de 1, c'est-à-dire des effets fixes.

L'estimateur à effets aléatoires est une **moyenne pondérée** de l'estimateur between et de l'estimateur within. Il est **plus précis** que les effets fixes, car il utilise aussi la variation « entre », mais il n'est **juste que si u_i est non corrélé avec x**.

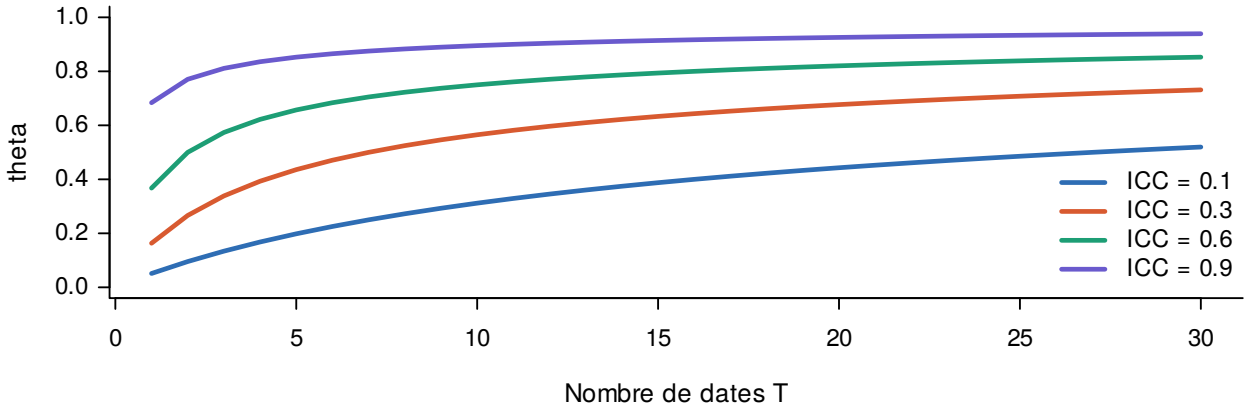


Figure 10: Valeur de theta (degré de centrage des effets aléatoires) selon le nombre de dates T, pour plusieurs ICC. Avec beaucoup de dates ou un ICC élevé, les effets aléatoires se rapprochent des effets fixes.

9.4 Exemples : un cas où les effets aléatoires conviennent, un cas où ils échouent

Tableau 8: Effets fixes (EF) et effets aléatoires (EA) dans deux situations. Vraie valeur de beta : -0,8.

	EF : coef	EF : e.-t.	EA : coef	EA : e.-t.	theta	Hausman p
Cas A : u non corrélé à x	-0.774	0.028	-0.772	0.028	0.859	0.079
Cas B : hôpitaux (u corrélé à x)	-0.854	0.045	0.343	0.043	0.576	0.000

Lecture.

- **Cas A** : les deux estimateurs retrouvent $-0{,}8$, et le test de Hausman ne rejette pas : les effets aléatoires sont acceptables. Ici, leurs écarts-types sont presque identiques, car θ est proche de 1 (l'ICC est élevé), et les effets aléatoires sont alors presque des effets fixes. Avec un ICC plus faible ou moins de dates, les effets aléatoires seraient nettement plus précis.
- **Cas B** : les effets aléatoires sont **biaisés**, car ils utilisent en partie la variation « entre », contaminée. Le test de Hausman rejette nettement : il faut garder les **effets fixes**.

10 Choisir entre les modèles : les tests

10.1 Trois tests, trois questions

Question	Test	H_0	Si on rejette H_0
MCO empilés ou effets fixes ?	**Fisher** (`pFtest`)	pas d'effet individuel (α_i tous égaux)	effets individuels présents
MCO empilés ou effets aléatoires ?	**Breusch-Pagan, multiplicateur de Lagrange** (`plmtest`)	$\sigma_u^2 = 0$	effets aléatoires présents
Effets fixes ou effets aléatoires ?	**Hausman** (`phtest`)	u_i non corrélé à x : les deux sont convergents, EA plus efficace	EA biaisé : garder les **EF**

10.2 Le test de Hausman en détail

L'idée est de comparer les deux estimations. Si l'hypothèse des effets aléatoires est vraie, les deux estimateurs visent la même valeur et doivent être proches. Si elle est fausse, seuls les effets fixes restent justes, et les deux s'écartent :

$$H = (\hat{\beta}_{\text{FE}} - \hat{\beta}_{\text{RE}})' \big[\widehat{V}(\hat{\beta}_{\text{FE}}) - \widehat{V}(\hat{\beta}_{\text{RE}})\big]^{-1} (\hat{\beta}_{\text{FE}} - \hat{\beta}_{\text{RE}}) \;\sim\; \chi^2(K) \text{ sous } H_0.$$

10.3 L'approche de Mundlak (effets aléatoires corrélés)

On ajoute au modèle à effets aléatoires **les moyennes individuelles des variables explicatives** :

$$y_{it} = \beta_0 + \beta x_{it} + \gamma\, \bar{x}_i + u_i + \varepsilon_{it}.$$

Le coefficient β obtenu est **identique à celui des effets fixes**, et on peut quand même estimer l'effet des variables fixes dans le temps. Tester $\gamma = 0$ est une version robuste du test de Hausman.

Tableau 10: Modèle de Mundlak sur les hôpitaux : le coefficient de x est celui des effets fixes ; celui de la moyenne individuelle mesure la contamination « entre ».

	Estimate	Std. Error	z-value	Pr(>|z|)
x	-0.854	0.045	-19.164	0
xbar	1.625	0.052	31.297	0

Le coefficient de $\bar{x}_i$ est **très significatif**. La moyenne individuelle de x est corrélée à l'effet individuel, ce qui confirme le choix des effets fixes.

À retenir

Règle de décision simple.

1. Faire le test de Fisher. S'il ne rejette pas, les MCO empilés suffisent (avec des écarts-types par grappe).
2. Sinon, faire le test de Hausman (ou celui de Mundlak). S'il rejette, garder les **effets fixes**. S'il ne rejette pas, les **effets aléatoires** sont acceptables et plus précis.

3. En pratique, beaucoup d'économistes partent directement des effets fixes quand la question est **causale**. Les effets aléatoires et les modèles mixtes servent plutôt à **décrire** et à **prédire**, ou quand des variables fixes dans le temps sont au cœur de la question.

11 Les modèles mixtes (modèles multiniveaux)

11.1 Même famille que les effets aléatoires, vue plus générale

En biostatistique, en épidémiologie et en psychologie, on parle plutôt de **modèles mixtes**, de **modèles multiniveaux** ou de **modèles hiérarchiques**. L'idée est celle des effets aléatoires, généralisée.

- **Effets fixes** (au sens des modèles mixtes) : les coefficients communs à toute la population, comme l'effet moyen du traitement ou du temps.
- **Effets aléatoires** : les écarts **propres à chaque groupe** (patient, hôpital), supposés tirés dans une loi normale.
- « **Mixte** » signifie que le modèle contient **les deux**.

Attention

Vocabulaire piège. « Effets fixes » n'a **pas le même sens** en économétrie et en biostatistique. En économétrie des panels, c'est une constante par individu, α_i. Dans un modèle mixte, ce sont les coefficients de population (β). Le « modèle à effets aléatoires » de l'économétrie est un modèle mixte à intercept aléatoire.

11.2 Intercept aléatoire

$$y_{ij} = \underbrace{\beta_0 + \beta_1 x_{ij}}_{\text{partie fixe}} + \underbrace{b_{0i}}_{\text{aléatoire}} + \varepsilon_{ij}, \qquad b_{0i} \sim \mathcal{N}(0, \tau_0^2),\ \varepsilon_{ij} \sim \mathcal{N}(0, \sigma^2).$$

Chaque groupe a **sa propre hauteur**, et tous ont **la même pente**. L'ICC vaut $\tau_0^2/(\tau_0^2 + \sigma^2)$.

11.3 Pente aléatoire

$$y_{ij} = \beta_0 + \beta_1 x_{ij} + b_{0i} + b_{1i}\, x_{ij} + \varepsilon_{ij}, \qquad \begin{pmatrix} b_{0i} \\ b_{1i} \end{pmatrix} \sim \mathcal{N}\left(0, \begin{pmatrix} \tau_0^2 & \tau_{01} \\ \tau_{01} & \tau_1^2 \end{pmatrix}\right).$$

Chaque groupe a **sa propre hauteur et sa propre pente**. Par exemple, l'effet du temps sur la tension artérielle diffère d'un patient à l'autre. On estime la pente **moyenne** β_1 et sa **dispersion** τ_1.

11.4 Exemple réel : privation de sommeil (`sleepstudy`)

Dans cette étude, 18 sujets sont privés de sommeil pendant 10 jours. Chaque jour, on mesure leur **temps de réaction** (en ms). C'est un panel typique de données de santé : des **mesures répétées** sur des patients.

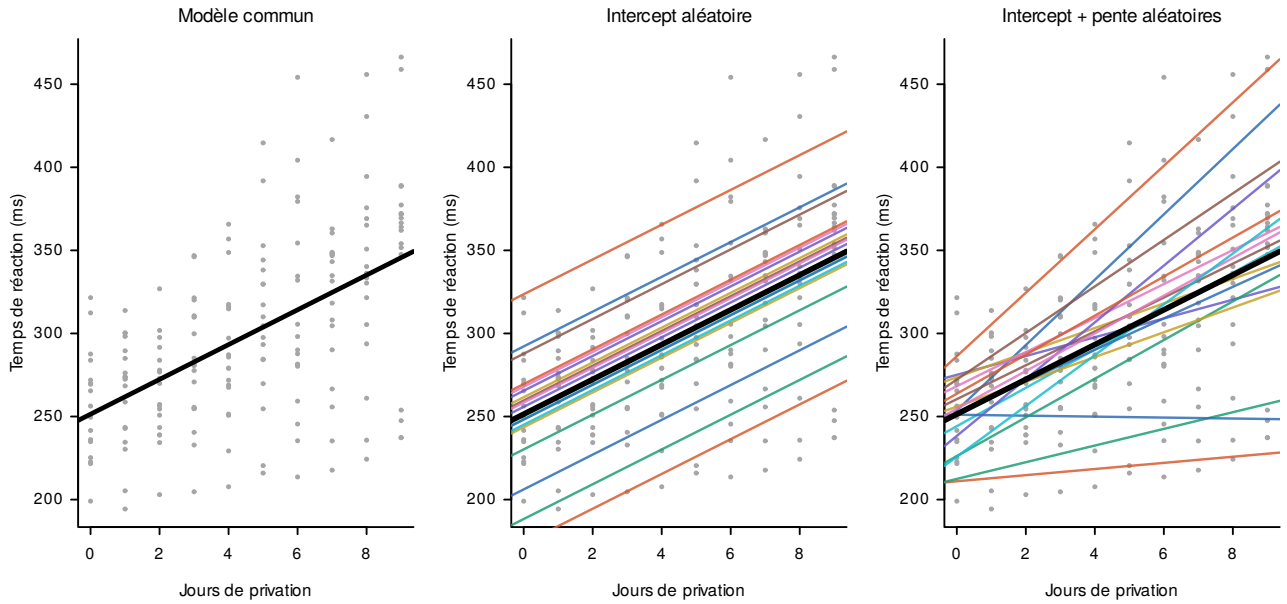


Figure 11: sleepstudy : temps de réaction de 18 sujets selon le nombre de jours de privation. Gauche : un seul modèle commun (MCO). Centre : intercept aléatoire (droites parallèles). Droite : intercept et pente aléatoires (chaque sujet a sa pente).

Tableau 11: Partie fixe du modèle à intercept et pente aléatoires (lme4::lmer, estimation REML).

	Estimation	Écart-type
Effet moyen d'un jour (beta1, ms)	10.47	1.55
Temps de réaction initial moyen (beta0, ms)	251.41	6.82

Tableau 12: Partie aléatoire : dispersion entre sujets.

Composante	Valeur
Écart-type des intercepts (tau0)	24.74
Écart-type des pentes (tau1)	5.92
Corrélation intercept–pente	0.07
Écart-type résiduel (sigma)	25.59

Lecture.

- En moyenne, chaque jour de privation allonge le temps de réaction d'environ **10.5 ms**.
- Cette pente **varie fortement d'un sujet à l'autre**, avec un écart-type d'environ 5.9 ms par jour. Environ 95 % des sujets ont une pente comprise entre -1.1 et 22.1 ms par jour.
- On peut comparer les deux modèles par un test du rapport de vraisemblance (`anova(m_ri, m_rs)`) : $p = 7.1 \times 10^{-10}$. La pente aléatoire est justifiée.

11.5 Le rétrécissement (*shrinkage*)

Les effets aléatoires prédits (les **BLUP**) sont **ramenés vers la moyenne**, d'autant plus que le groupe a peu de données ou est très bruité. Un sujet au comportement extrême mais mal mesuré « emprunte de l'information » aux autres. Cela donne des estimations individuelles **plus stables** que des régressions séparées.

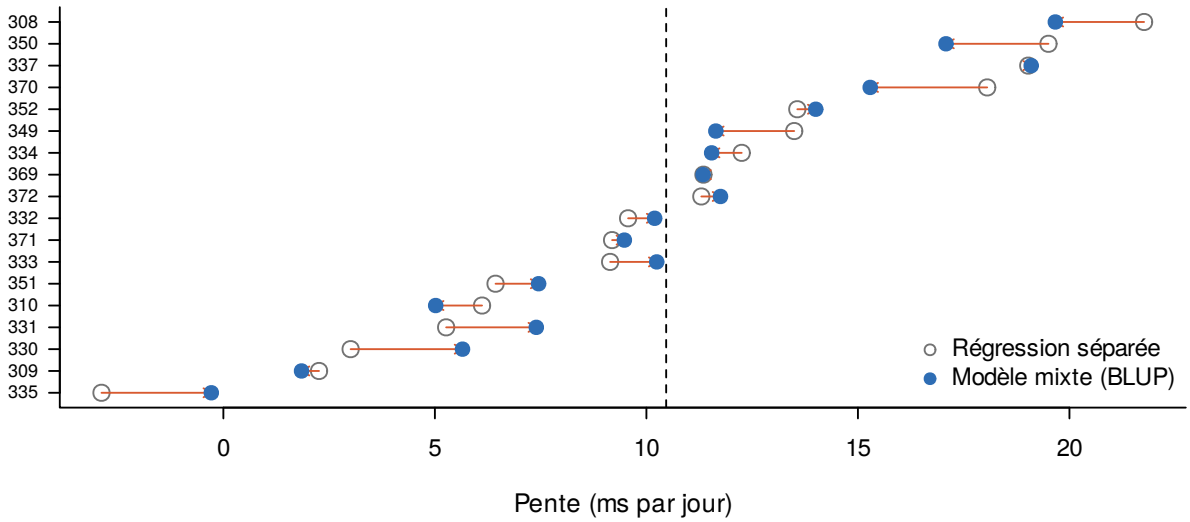


Figure 12: Rétrécissement : pour chaque sujet, la pente estimée par une régression séparée (cercle) et la pente prédite par le modèle mixte (point plein). Les flèches vont toujours vers la pente moyenne (trait vertical).

11.6 Niveaux emboîtés et autres extensions

- **Plusieurs niveaux** : des mesures dans des patients, eux-mêmes dans des hôpitaux. On écrit alors `(1 | hopital/patient)`.
- **Réponse binaire ou comptage** : on utilise un modèle linéaire généralisé mixte (`glmer`), par exemple une régression logistique avec intercept aléatoire par hôpital.
- **Estimation** : par maximum de vraisemblance (ML), ou par **REML** (maximum de vraisemblance restreint), qui estime mieux les variances. Pour comparer deux modèles dont la **partie fixe** diffère, il faut utiliser ML.

À retenir

Effets fixes ou modèle mixte ?

- Le **modèle mixte** sert à **décrire et prédire**, à quantifier la variabilité entre groupes (l'ICC), à garder des variables fixes dans le temps, et à profiter du rétrécissement quand les groupes sont petits.
- Il suppose cependant que les effets aléatoires sont **non corrélés aux variables explicatives**, comme les effets aléatoires.
- Pour une **question causale** avec un risque de facteur caché permanent, les **effets fixes** (ou la version de Mundlak) sont plus sûrs.

12 Inférence robuste et diagnostics

12.1 Pourquoi les écarts-types usuels sont souvent faux

Même avec un estimateur sans biais, trois problèmes faussent les écarts-types en panel :

1. **Autocorrélation** : les erreurs d'un même individu sont corrélées d'une année sur l'autre (inertie, chocs persistants).
2. **Hétéroscédasticité** : la variance des erreurs diffère selon l'individu (les grands hôpitaux fluctuent moins).
3. **Dépendance entre individus** : un choc commun touche plusieurs individus la même année (régions voisines).

12.2 La solution standard : les écarts-types robustes par grappe (*clustered*)

On autorise **n'importe quelle corrélation entre les erreurs d'un même individu**, ainsi qu'une hétéroscédasticité, avec la formule « sandwich » d'Arellano :

$$\widehat{V}(\hat{\beta}) = \Big(\sum_i \tilde{X}_i'\tilde{X}_i\Big)^{-1}\Big(\sum_i \tilde{X}_i'\hat{e}_i\hat{e}_i'\tilde{X}_i\Big)\Big(\sum_i \tilde{X}_i'\tilde{X}_i\Big)^{-1}.$$

Elle n'est fiable que si le **nombre de grappes est suffisant** (en pratique, au moins 30 à 50 individus).

Tableau 13: Effets fixes avec des erreurs et un x fortement persistants (AR(1), phi = 0,9) : l'écart-type usuel est trop petit.

	Écart_type
Usuel	0.044
Robuste hétéroscédasticité (White)	0.045
Robuste par grappe (Arellano)	0.087

Lecture. L'écart-type robuste par grappe est **nettement plus grand** que l'écart-type usuel : avec ce dernier, on surestimerait la précision et on rejetterait trop souvent l'hypothèse nulle.

12.3 Les tests de diagnostic à connaître

Problème	Test	Fonction R (`plm`)	H_0
Autocorrélation des erreurs	Wooldridge, Breusch-Godfrey	`pwartest`, `pbgtest`	pas d'autocorrélation
Hétéroscédasticité	Breusch-Pagan	`lmtest::bptest`	variance constante
Dépendance entre individus	Pesaran CD	`pcdtest`	indépendance entre individus
Racine unitaire (grand T)	Levin-Lin-Chu, Im-Pesaran-Shin	`purtest`	racine unitaire (non stationnaire)

Sur l'exemple simulé, le test de Wooldridge donne p = 9.4×10^{-67} : on détecte bien l'autocorrélation.

13 Panels dynamiques

13.1 Le modèle

On ajoute la **valeur passée** de la variable expliquée. Cela traduit une inertie : l'habitude tabagique, la persistance d'un état de santé, l'ajustement progressif d'un budget.

$$y_{it} = \rho\, y_{i,t-1} + \beta x_{it} + \alpha_i + \varepsilon_{it}.$$

Le coefficient ρ mesure la **persistance**. On distingue l'effet **de court terme** β de l'effet **de long terme** $\beta/(1-\rho)$.

13.2 Le biais de Nickell

Avec des effets fixes, le centrage crée une corrélation mécanique entre $y_{i,t-1} - \bar{y}_{i,-1}$ et $\varepsilon_{it} - \bar{\varepsilon}_i$. L'estimateur within de ρ est donc **biaisé vers le bas**, d'autant plus que T est petit. Le biais vaut approximativement $-(1+\rho)/(T-1)$.

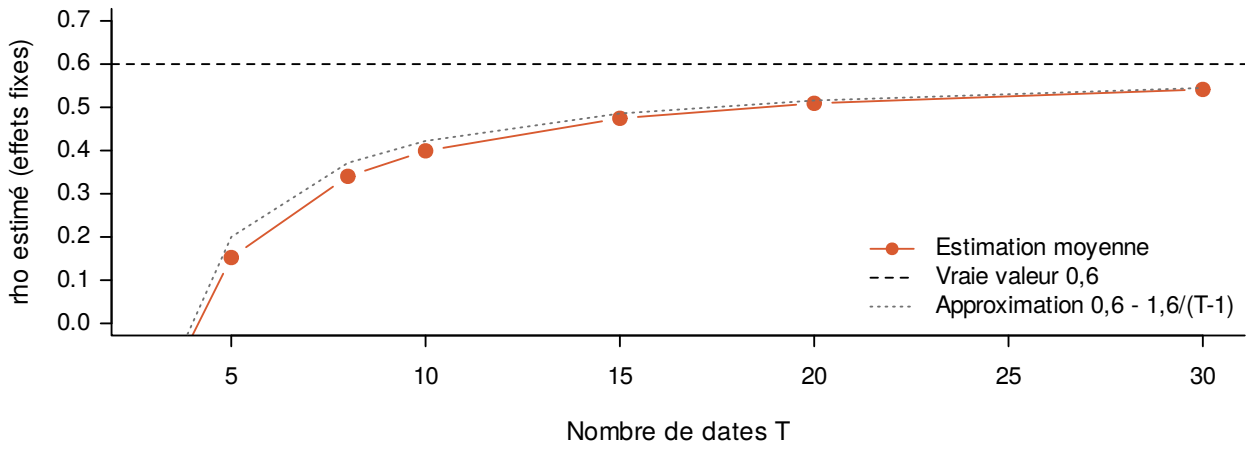


Figure 13: Biais de Nickell : estimation de rho (vraie valeur 0,6) par effets fixes, moyenne sur 200 simulations de 100 individus, selon T. Le biais est fort pour T petit et s'efface quand T grandit.

13.3 Les solutions : variables instrumentales et GMM

- **Anderson-Hsiao** : on différencie le modèle pour éliminer α_i, $\Delta y_{it} = \rho \Delta y_{i,t-1} + \beta \Delta x_{it} + \Delta \varepsilon_{it}$, puis on **instrumente** $\Delta y_{i,t-1}$ par $y_{i,t-2}$, qui est corrélé à $\Delta y_{i,t-1}$ mais pas à $\Delta \varepsilon_{it}$.
- **Arellano-Bond (GMM en différences)** : on utilise **tous** les retards disponibles $y_{i,t-2}, y_{i,t-3}, \ldots$ comme instruments, par la méthode des moments généralisés.
- **Blundell-Bond (GMM système)** : on ajoute les équations en niveau, ce qui est préférable quand ρ est proche de 1.
- **Diagnostics** : le test d'Arellano-Bond doit montrer une autocorrélation d'ordre 1 dans les résidus différenciés (c'est normal) mais **pas d'ordre 2**. Le test de **Sargan/Hansen** vérifie la validité des instruments. Il faut aussi éviter d'avoir trop d'instruments par rapport à N.

Tableau 15: Estimation de rho (vraie valeur 0,6) sur 200 individus × 8 dates. Les MCO surestiment (ils ignorent alpha_i), les effets fixes sous-estiment (biais de Nickell), le GMM corrige.

Estimateur	rho
MCO empilés	0.933
Effets fixes (within)	0.358
Arellano-Bond (GMM, 2 étapes)	0.663

14 Autres situations à connaître

- **Réponse binaire** (malade / non malade). Les effets fixes passent par le **logit conditionnel** (`survival::clogit`, `bife`). Les effets aléatoires passent par un **probit** ou un **logit mixte** (`glmer(..., family = binomial)`). Il n'existe pas de « probit à effets fixes » simple.
- **Comptages** (nombre de décès, de consultations) : la **régression de Poisson à effets fixes** (`pglm`, `fixest::fepois`) est robuste et très utilisée en épidémiologie, avec la population en *offset*.
- **Panels non cylindrés et attrition** : les méthodes fonctionnent, mais si les sorties du panel dépendent de y (les patients les plus malades abandonnent l'étude), les résultats sont biaisés. Il faut alors comparer les profils des sortants et des restants, ou utiliser une pondération par l'inverse de la probabilité de rester.
- **Panels à T grand** (macro-panels) : il faut tester la stationnarité par des tests de racine unitaire en panel (Levin-Lin-Chu, Im-Pesaran-Shin) et, si les séries sont non stationnaires, la **cointégration** en panel. Sinon, on risque une régression fallacieuse, comme en séries temporelles.
- **Effets hétérogènes** : la pente peut varier selon l'individu. On utilise alors des modèles mixtes à pente aléatoire, ou des estimateurs par groupe moyenné (*mean group*).

15 Synthèse

15.1 Les modèles en un tableau

Modèle	Équation	Hypothèse sur α_i	Utilise	Estime l'effet des variables fixes ?
MCO empilés	$y_{it} = \beta_0 + \beta x_{it} + u_{it}$	non corrélé à x, ou absent	tout	oui
Between	$\bar{y}_i = \beta_0 + \beta \bar{x}_i + \bar{u}_i$	non corrélé à x	« entre » seulement	oui
Effets fixes	$y_{it} = \alpha_i + \beta x_{it} + \varepsilon_{it}$	**peut être corrélé** à x	« dans » seulement	**non**
Effets fixes à deux dimensions	$+\lambda_t$	peut être corrélé ; chocs communs captés	« dans », hors chocs communs	non
Effets aléatoires / mixtes	$y_{it} = \beta_0 + \beta x_{it} + u_i + \varepsilon_{it}$	**non corrélé** à x	« entre » et « dans » (pondérés)	oui
Mundlak	EA $+\gamma \bar{x}_i$	corrélation autorisée via $\bar{x}_i$	« dans » pour β	oui
Dynamique (GMM)	$+\rho y_{i,t-1}$	peut être corrélé	différences instrumentées	non (en différences)

15.2 La démarche en huit étapes

1. **Mettre les données au format long** et déclarer les index (individu, date). Vérifier si le panel est cylindré.
2. **Visualiser** : trajectoires, nuages colorés par individu, moyennes par date.
3. **Décomposer la variance** en « entre » et « dans », pour savoir où est l'information.
4. **Estimer les MCO empilés** comme point de départ.
5. **Estimer les effets fixes** (et les effets fixes à deux dimensions si des chocs communs sont plausibles), puis faire le test de Fisher.
6. **Estimer les effets aléatoires**, faire le test de Breusch-Pagan, puis le test de Hausman ou de Mundlak.
7. **Diagnostiquer** (autocorrélation, hétéroscédasticité, dépendance entre individus) et utiliser des **écarts-types par grappe**.
8. **Interpréter** : effet « dans » ou « entre », causal ou descriptif, de court ou de long terme (si le modèle est dynamique).

15.3 Principales fonctions R

Tâche	Fonction
Déclarer un panel	`plm::pdata.frame(d, index = c("id", "temps"))`
MCO empilés, between, within, différences premières, effets aléatoires	`plm(y ~ x, data, model = "pooling" / "between" / "within" / "fd" / "random")`
Effets à deux dimensions	`plm(..., model = "within", effect = "twoways")`
Effets individuels estimés	`fixef(modele)`

Tâche	Fonction
Tests de Fisher, Breusch-Pagan, Hausman	`pFtest`, `plmtest`, `phtest`
Écarts-types robustes par grappe	`lmtest::coeftest(m, vcov = vcovHC(m, cluster = "group"))`
Autocorrélation, dépendance, racine unitaire	`pwartest`, `pbgtest`, `pcdtest`, `purtest`
Panel dynamique (GMM)	`pgmm(y ~ lag(y, 1) + x | lag(y, 2:99), ...)`
Modèles mixtes	`lme4::lmer(y ~ x + (1 | id))`, `(x | id)`, `glmer(...)`
Grands effets fixes, Poisson à effets fixes	`fixest::feols`, `fixest::fepois`

15.4 Glossaire

- **Panel cylindré / non cylindré** : toutes les cases (individu, date) sont observées ou non.
- **Hétérogénéité non observée** : les différences permanentes entre individus qui ne sont pas mesurées (α_i).
- **Variation within / between** : la variation d'un individu autour de sa propre moyenne, ou la variation des moyennes entre individus.
- **Effets fixes (économétrie)** : une constante propre à chaque individu, éliminée par centrage. Aucune hypothèse sur sa corrélation avec x.
- **Effets aléatoires** : l'effet individuel vu comme une variable aléatoire non corrélée à x. On estime sa variance.
- **ICC** : la part de la variance totale due aux différences entre individus.
- **Modèle mixte** : un modèle à la fois avec des coefficients de population et des effets aléatoires par groupe (intercepts et pentes).
- **BLUP / rétrécissement** : la prédiction des effets aléatoires, ramenée vers la moyenne.
- **Test de Hausman** : il compare les effets fixes et les effets aléatoires. S'il rejette, il faut garder les effets fixes.
- **Écarts-types par grappe** : des écarts-types robustes à la corrélation des erreurs d'un même individu.
- **Biais de Nickell** : le biais des effets fixes quand le modèle contient $y_{i,t-1}$ et que T est petit.
- **Doubles différences** : l'effet d'une politique, estimé par des effets fixes à deux dimensions, sous l'hypothèse des tendances parallèles.

Références de base : J. M. Wooldridge, *Econometric Analysis of Cross Section and Panel Data* ; B. H. Baltagi, *Econometric Analysis of Panel Data* ; Y. Croissant et G. Millo, *Panel Data Econometrics with R* (package `plm`) ; D. Bates et al., *Fitting Linear Mixed-Effects Models Using lme4*.