Les taxes sur la bière réduisent-elles la mortalité routière ?

Projet complet de données de panel : 48 États américains, 1982-1988 (jeu de données Fatalities)

Christian TOSSE — M2 Mathématiques des Données

Novembre 2026

Table des matières

Introduction **2**
La question . . . 2
Ce que le projet montre . . . 2

1 Les données **2**
1.1 Charger les données et lire leur structure . . . 2
1.2 Les variables utilisées . . . 3
1.3 Déclarer le panel . . . 4

2 Exploration **4**
2.1 Les trajectoires des États . . . 4
2.2 Où se trouve l'information : « entre » ou « dans » ? . . . 5

3 L'analyse naïve : une coupe transversale **5**

4 Les MCO empilés : toutes les années ensemble **7**

5 L'idée clé : comparer chaque État à lui-même **8**
5.1 Intuition avec deux années : « avant–après » . . . 8

6 Le modèle à effets fixes (toutes les années) **10**
6.1 Le modèle . . . 10
6.2 Vérification : la même chose avec des indicatrices d'État (LSDV) . . . 10
6.3 Interprétation . . . 10
6.4 Les effets propres aux États . . . 11
6.5 Faut-il des effets individuels ? Le test de Fisher . . . 12

7 Ajouter des effets temporels (deux dimensions) **12**

8 Effets aléatoires : un modèle concurrent **13**
8.1 Le test de Hausman : effets fixes ou aléatoires ? . . . 14

9 Ajouter des variables de contrôle **14**
9.1 Tableau récapitulatif des modèles . . . 15

10 Diagnostics : les écarts-types sont-ils fiables ? **17**

11 Bonus : le même problème vu comme un modèle mixte **17**

12 Conclusion, limites et préparation de l'entretien **18**
12.1 Ce que montre le projet 18
12.2 Limites 18
12.3 Phrase possible pour une lettre de motivation 18
12.4 Questions probables en entretien 18
12.5 Pour aller plus loin 19

Introduction

La question

Les accidents de la route sont une cause majeure de décès évitables, et l'alcool y joue un grand rôle. Une politique souvent proposée consiste à **taxer davantage l'alcool**, pour réduire la consommation et donc les accidents. **Est-ce que ça marche ?**

On y répond avec des **données de panel** : le taux de mortalité routière des **48 États continentaux des États-Unis**, chaque année de **1982 à 1988**, ainsi que la taxe sur la bière de chaque État. Ces données sont célèbres en économétrie (Stock et Watson, *Introduction to Econometrics*, chapitre 10). Elles illustrent parfaitement **pourquoi on a besoin des données de panel**.

Ce que le projet montre

1. Une analyse naïve trouve que **plus la taxe est élevée, plus il y a de morts**. C'est absurde.
2. La raison : des **différences cachées entre États** (culture de la route, ruralité, densité de la police) qui biaisent la comparaison.
3. Les **effets fixes**, qui comparent chaque État à lui-même dans le temps, inversent le signe.
4. On vérifie ensuite la solidité du résultat : effets temporels, effets aléatoires, test de Hausman, variables de contrôle, écarts-types robustes, modèle mixte.

Chaque notion est rappelée avant d'être utilisée (les détails sont dans le *Guide des données de panel*). Chaque ligne de code est commentée, et chaque résultat est interprété.

1 Les données

1.1 Charger les données et lire leur structure

```
library(AER)        # contient le jeu de données Fatalities (Stock & Watson)
library(plm)        # économétrie des données de panel : pooling, within, random,
 ↪  tests
library(lmtest)     # coeftest() : tableaux de coefficients avec écarts-types choisis
library(sandwich)   # écarts-types robustes (hétéroscédasticité, grappes)
library(lme4)       # modèles mixtes (lmer)
data("Fatalities")                      # charge les données en mémoire
F <- Fatalities                         # copie sous un nom court
dim(F)                                  # nombre de lignes et de colonnes
```

```
## [1] 336  34
```

```r
head(F[, c("state", "year", "fatal", "pop", "beertax")], 8)   # premières lignes des variables clés
```

```
##   state year fatal     pop   beertax
## 1    al 1982   839 3942002 1.5393795
## 2    al 1983   930 3960008 1.7889907
## 3    al 1984   932 3988992 1.7142856
## 4    al 1985   882 4021008 1.6525424
## 5    al 1986  1081 4049994 1.6099070
## 6    al 1987  1110 4082999 1.5599999
## 7    al 1988  1023 4101992 1.5014436
## 8    az 1982   724 2896996 0.2147971
```

Lecture. Il y a **336 lignes**. Chaque ligne est un couple **(État, année)** : c'est le **format long**. Les deux colonnes d'index sont `state` (l'individu) et `year` (la date).

1.2 Les variables utilisées

Variable	Signification	Varie dans le temps ?
`state`, `year`	identifiant de l'État et année	—
`fatal`, `pop`	nombre de morts sur la route, population	oui
`beertax`	taxe sur une caisse de bière, en dollars de 1988	oui (rarement)
`drinkage`	âge minimum légal pour boire de l'alcool	oui (certains États)
`jail`, `service`	peine de prison ou travaux d'intérêt général obligatoires pour une première conduite en état d'ivresse	oui (rarement)
`miles`	nombre moyen de miles parcourus par conducteur	oui
`unemp`	taux de chômage (%)	oui
`income`	revenu par habitant (dollars de 1987)	oui

On construit la variable étudiée, le **taux de mortalité pour 10 000 habitants**. On rapporte le nombre de morts à la population pour comparer des États de tailles très différentes.

```r
F$fr <- F$fatal / F$pop * 10000              # taux de mortalité routière pour 10 000 habitants
summary(F[, c("fr", "beertax", "miles", "unemp", "income")])   # résumé des variables quantitatives
```

```
##        fr             beertax            miles           unemp      
##  Min.   :0.8212   Min.   :0.04331   Min.   : 4576   Min.   : 2.400  
##  1st Qu.:1.6237   1st Qu.:0.20885   1st Qu.: 7183   1st Qu.: 5.475  
##  Median :1.9560   Median :0.35259   Median : 7796   Median : 7.000  
##  Mean   :2.0404   Mean   :0.51326   Mean   : 7891   Mean   : 7.347  
```

```
##  3rd Qu.:2.4179   3rd Qu.:0.65157   3rd Qu.: 8504   3rd Qu.: 8.900
##  Max.   :4.2178   Max.   :2.72076   Max.   :26148   Max.   :18.000
##      income
##  Min.   : 9514
##  1st Qu.:12086
##  Median :13763
##  Mean   :13880
##  3rd Qu.:15175
##  Max.   :22193
```

Lecture. En moyenne, on compte environ **2.04 morts pour 10 000 habitants** par an, avec de grands écarts entre États et années (de 0.82 à 4.22). La taxe sur la bière va de 0.04 à 2.72 dollars par caisse.

1.3 Déclarer le panel

```
p <- pdata.frame(F, index = c("state", "year"))    # déclare l'individu (state) et la
 ↪  date (year)
pdim(p)                                             # dimensions : N, T, panel cylindré
 ↪  ou non
```

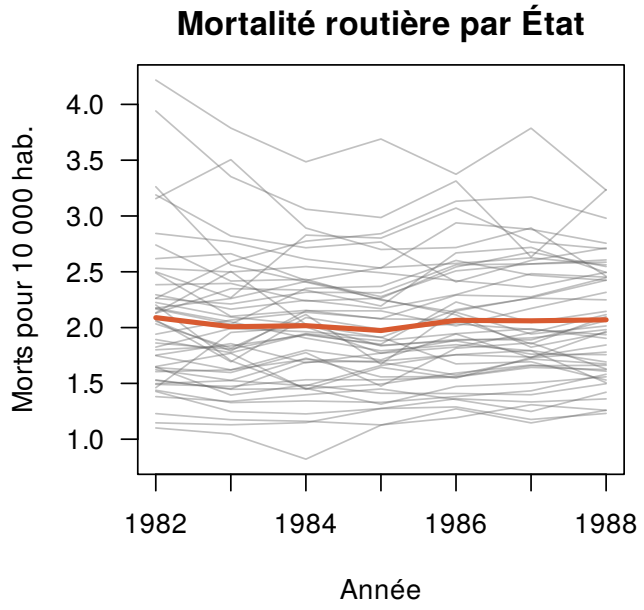
```
## Balanced Panel: n = 48, T = 7, N = 336
```

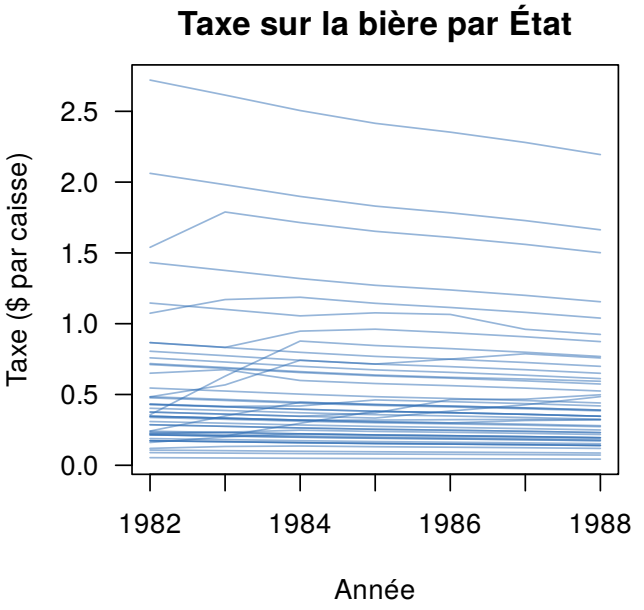
Lecture. Le panel est **cylindré** (*balanced*) : **N = 48 États**, **T = 7 années**, toutes observées, soit 48 × 7 = 336 lignes. C'est un **micro-panel** : beaucoup d'individus pour peu de dates.

2 Exploration

2.1 Les trajectoires des États

```
par(mfrow = c(1, 2), mar = c(4, 4.2, 2.5, 1), las = 1)      # deux graphiques côte à
 ↪  côte
an <- as.numeric(as.character(F$year))                      # année en numérique pour
 ↪  les graphiques
plot(NA, xlim = c(1982, 1988), ylim = range(F$fr), xlab = "Année",
     ylab = "Morts pour 10 000 hab.", main = "Mortalité routière par État")   # cadre
      ↪  vide
for (s in unique(F$state)) {                                # une ligne grise par État
  z <- F$state == s; lines(an[z], F$fr[z], col = adjustcolor("grey40", 0.4))
}
lines(1982:1988, tapply(F$fr, F$year, mean), col = "#D85A30", lwd = 3)        #
 ↪  moyenne nationale
plot(NA, xlim = c(1982, 1988), ylim = range(F$beertax), xlab = "Année",
     ylab = "Taxe ($ par caisse)", main = "Taxe sur la bière par État")      # cadre
      ↪  vide
for (s in unique(F$state)) {                                # une ligne par État
  z <- F$state == s; lines(an[z], F$beertax[z], col = adjustcolor("#2E6DB4", 0.5))
}
```





Lecture.

- **Mortalité** : les États diffèrent beaucoup de niveau, avec des écarts qui persistent d'une année sur l'autre. La moyenne nationale (orange) **baisse** sur la période (meilleure sécurité des voitures, campagnes de prévention…).
- **Taxe** : les lignes sont presque **horizontales**. La taxe **change peu dans le temps** pour un même État. Elle diffère surtout **entre** États. C'est crucial pour la suite : les effets fixes n'utiliseront que les petits changements dans le temps.

2.2 Où se trouve l'information : « entre » ou « dans » ?

```
decomp <- function(v, g) {                          # décompose la variabilité d'une
 ↪  variable v selon le groupe g
  tot  <- sum((v - mean(v))^2)                      # somme des carrés totale
  dans <- sum((v - ave(v, g))^2)                    # somme des carrés « dans » (autour
 ↪  de la moyenne de l'État)
  c(part_entre = 1 - dans / tot, part_dans = dans / tot)   # parts « entre » et « dans
   ↪  »
}
round(rbind(mortalite = decomp(F$fr, F$state), taxe = decomp(F$beertax, F$state)), 3)
```

```
##           part_entre part_dans
## mortalite      0.901     0.099
## taxe           0.987     0.013
```

Lecture. Environ **1.3 %** seulement de la variabilité de la taxe vient de changements **dans le temps** ; le reste vient des différences **entre** États. Les effets fixes vont donc s'appuyer sur une petite part de l'information disponible. Ils seront plus justes, mais moins précis.

3 L'analyse naïve : une coupe transversale

On commence comme si on ne disposait que **d'une seule année** : on compare les États entre eux en 1982, puis en 1988.

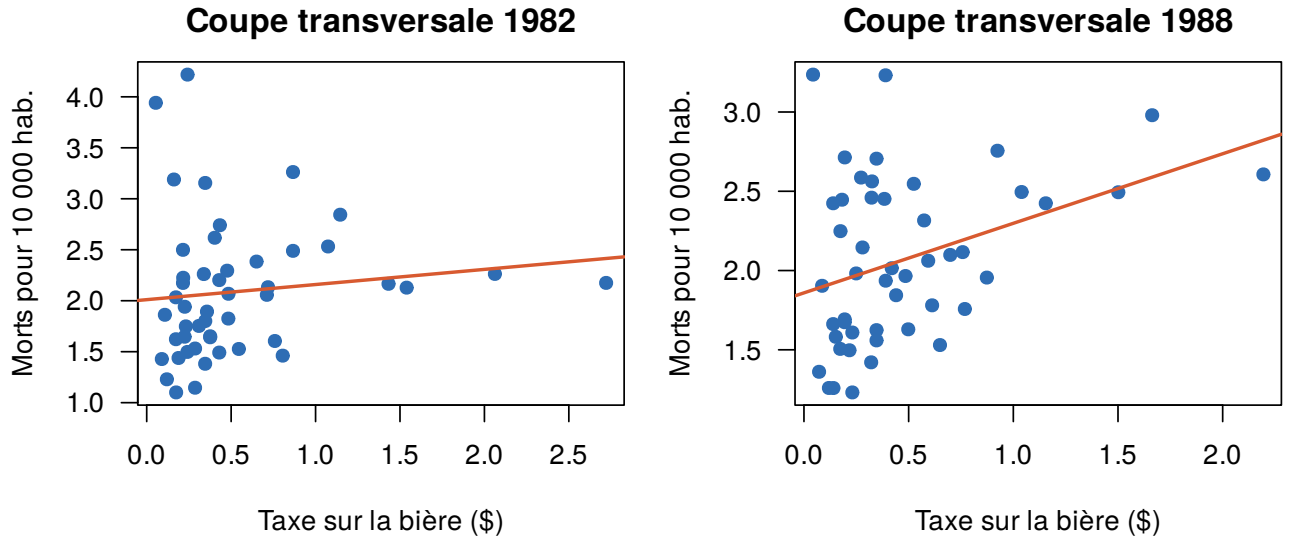
```r
c82 <- lm(fr ~ beertax, data = F, subset = year == "1982")    # régression sur la
 ↪  seule année 1982
c88 <- lm(fr ~ beertax, data = F, subset = year == "1988")    # régression sur la
 ↪  seule année 1988
coeftest(c82, vcov = vcovHC(c82, type = "HC1"))               # coefficients 1982,
 ↪  écarts-types robustes
```

```
##
## t test of coefficients:
##
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)  2.01038    0.14957 13.4408   <2e-16 ***
## beertax      0.14846    0.13261  1.1196   0.2687
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```r
coeftest(c88, vcov = vcovHC(c88, type = "HC1"))               # coefficients 1988,
 ↪  écarts-types robustes
```

```
##
## t test of coefficients:
##
##             Estimate Std. Error t value  Pr(>|t|)
## (Intercept)  1.85907    0.11461 16.2205 < 2.2e-16 ***
## beertax      0.43875    0.12786  3.4314  0.001279 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```r
par(mfrow = c(1, 2), mar = c(4, 4.2, 2.5, 1), las = 1)
for (a in c("1982", "1988")) {                                  # un
 ↪  graphique par année
  z <- F$year == a                                             # lignes de
 ↪  l'année a
  plot(F$beertax[z], F$fr[z], pch = 19, col = "#2E6DB4", xlab = "Taxe sur la bière
   ↪  ($)",
       ylab = "Morts pour 10 000 hab.", main = paste("Coupe transversale", a))
  abline(lm(fr ~ beertax, data = F[z, ]), col = "#D85A30", lwd = 2)       # droite des
   ↪  moindres carrés
}
```



Lecture : le paradoxe. Les deux années donnent une pente **positive** : 0.15 en 1982 (non significative) et 0.44 en 1988 (significative). Autrement dit, **plus la taxe est élevée, plus il y a de morts**. Pris au pied de la lettre, ce résultat dirait qu'**augmenter la taxe tue**. Ce n'est pas crédible.

Attention

Pourquoi ce résultat est faux : l'hétérogénéité non observée. Les États à forte taxe (souvent dans le Sud) diffèrent des autres de bien des façons durables, qui ne sont pas mesurées : routes rurales plus dangereuses, longues distances, culture de la voiture, contrôles d'alcoolémie plus ou moins fréquents, attitude sociale envers l'alcool au volant. Ces facteurs augmentent la mortalité **et** sont associés à des taxes élevées. La régression attribue leur effet à la taxe : c'est un **biais de variable omise**.

4 Les MCO empilés : toutes les années ensemble

Notion. On empile les 336 lignes et on fait une seule régression : $\text{fr}_{it} = \beta_0 + \beta_1 \, \text{taxe}_{it} + u_{it}$. On utilise plus de données, mais on ne corrige pas le biais.

```
m_pool <- plm(fr ~ beertax, data = p, model = "pooling")        # MCO empilés
coeftest(m_pool, vcov = vcovHC(m_pool, cluster = "group", type = "HC1"))    #
 ↪  écarts-types robustes par État
```

```
##
## t test of coefficients:
##
##              Estimate Std. Error t value  Pr(>|t|)
## (Intercept)  1.85331    0.11745  15.779 < 2.2e-16 ***
## beertax      0.36461    0.11861   3.074  0.002286 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Lecture. Le coefficient est **positif** (0.365) et significatif. On retrouve le paradoxe, puisque les MCO empilés utilisent surtout la variation « entre » États, contaminée par les différences cachées. On calcule des écarts-types **par grappe (par État)** : les 7 observations d'un même État ne sont pas indépendantes.

5 L'idée clé : comparer chaque État à lui-même

5.1 Intuition avec deux années : « avant–après »

Avant la méthode générale, voici l'idée la plus simple. On regarde **le changement** de chaque État entre 1982 et 1988 :

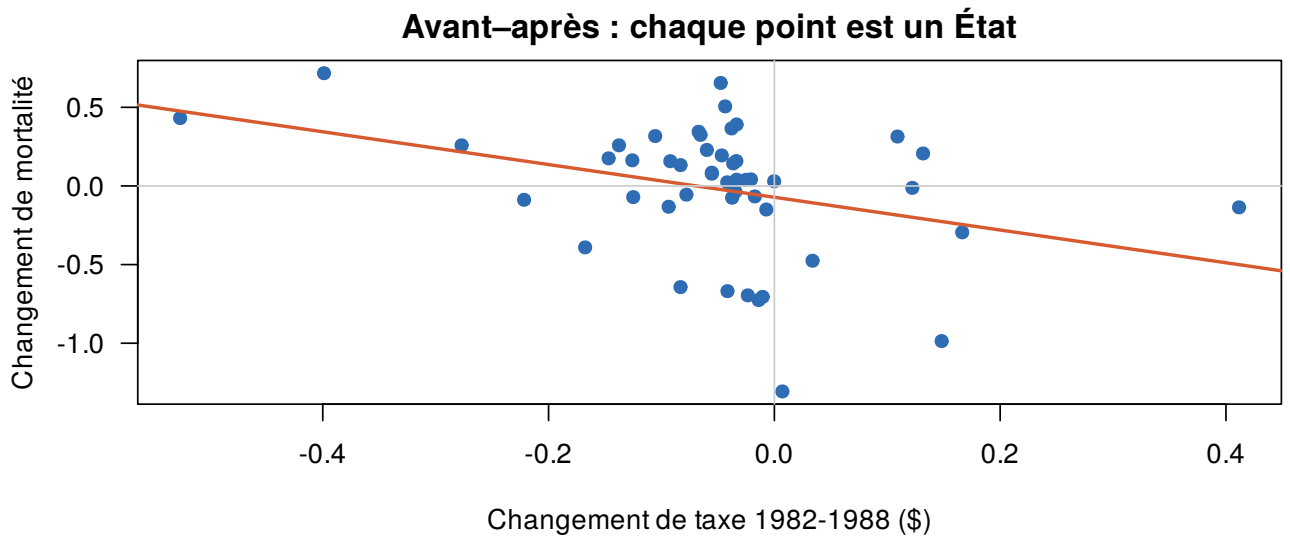
$$\text{fr}_{i,1988} - \text{fr}_{i,1982} = \beta_0 + \beta_1(\text{taxe}_{i,1988} - \text{taxe}_{i,1982}) + \text{erreur}.$$

Tout ce qui est **propre à l'État et stable dans le temps** (culture, géographie…) est présent en 1982 comme en 1988. **Il s'annule dans la différence.**

```
d82 <- F[F$year == "1982", ]; d88 <- F[F$year == "1988", ]     # les deux années
 ↪  extrêmes
stopifnot(all(d82$state == d88$state))                          # vérifie que les
 ↪  États sont dans le même ordre
dfr  <- d88$fr - d82$fr                                         # changement de
 ↪  mortalité de chaque État
dtax <- d88$beertax - d82$beertax                               # changement de taxe
 ↪  de chaque État
m_diff <- lm(dfr ~ dtax)                                        # régression des
 ↪  changements
coeftest(m_diff, vcov = vcovHC(m_diff, type = "HC1"))           # coefficients avec
 ↪  écarts-types robustes
```

```
##
## t test of coefficients:
##
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -0.072037   0.065355 -1.1022 0.276091
## dtax        -1.040973   0.355006 -2.9323 0.005229 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
par(mar = c(4, 4.2, 2, 1), las = 1)
plot(dtax, dfr, pch = 19, col = "#2E6DB4", xlab = "Changement de taxe 1982-1988 ($)",
     ylab = "Changement de mortalité", main = "Avant-après : chaque point est un
      ↪  État")
abline(m_diff, col = "#D85A30", lwd = 2); abline(h = 0, v = 0, col = "grey80")    #
 ↪  droite et axes
```



Lecture. La pente devient **négative** : -1.04. Les États qui ont **augmenté** leur taxe ont vu leur mortalité **baisser** davantage. En comparant chaque État à lui-même, le paradoxe disparaît. La constante (-0.072) reflète la baisse commune à tous les États sur la période.

6 Le modèle à effets fixes (toutes les années)

6.1 Le modèle

$$\text{fr}_{it} = \alpha_i + \beta\,\text{taxe}_{it} + \varepsilon_{it}.$$

Chaque État a **sa propre constante** α_i, qui résume tout ce qui lui est propre et stable. On l'élimine en **centrant** chaque variable sur la moyenne de l'État (la transformation *within*), puis on estime β sur les écarts. On utilise ainsi les 7 années, et pas seulement 1982 et 1988.

```
m_fe <- plm(fr ~ beertax, data = p, model = "within")            # effets fixes États
 ↪  (centrage within)
coeftest(m_fe, vcov = vcovHC(m_fe, cluster = "group", type = "HC1"))   # écarts-types
 ↪  robustes par État
```

```
##
## t test of coefficients:
##
##         Estimate Std. Error t value Pr(>|t|)
## beertax -0.65587    0.28880  -2.271  0.02388 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

6.2 Vérification : la même chose avec des indicatrices d'État (LSDV)

```
m_lsdv <- lm(fr ~ beertax + state, data = F)          # une indicatrice par État (47 +
 ↪  la constante)
coef(m_lsdv)["beertax"]                               # même coefficient que le within
```

```
##    beertax
## -0.6558737
```

```
length(coef(m_lsdv))                                  # 49 coefficients : constante +
 ↪  taxe + 47 indicatrices
```

```
## [1] 49
```

Les deux méthodes donnent **exactement le même coefficient** (-0.656). Le within évite simplement d'afficher les 48 constantes.

6.3 Interprétation

```
b <- coef(m_fe)["beertax"]                                    # effet estimé d'un
 ↪  dollar de taxe en plus
sd_dans <- sd(F$beertax - ave(F$beertax, F$state))            # écart-type de la taxe
 ↪  « dans » les États
c(effet_1_dollar = b,                                         # effet d'une hausse de
 ↪  1 $ par caisse
  en_pct_moyenne = 100 * b / mean(F$fr),                      # en % du taux moyen de
   ↪  mortalité
  effet_hausse_typique = b * sd_dans,                         # effet d'une hausse «
   ↪  typique » de la taxe dans un État
```

```r
morts_evites_par_an = -b * 0.5 * sum(F$pop[F$year == "1988"]) / 10000)    # morts
 ↪  évités par an pour +0,50 $ partout (pop. 1988)
```

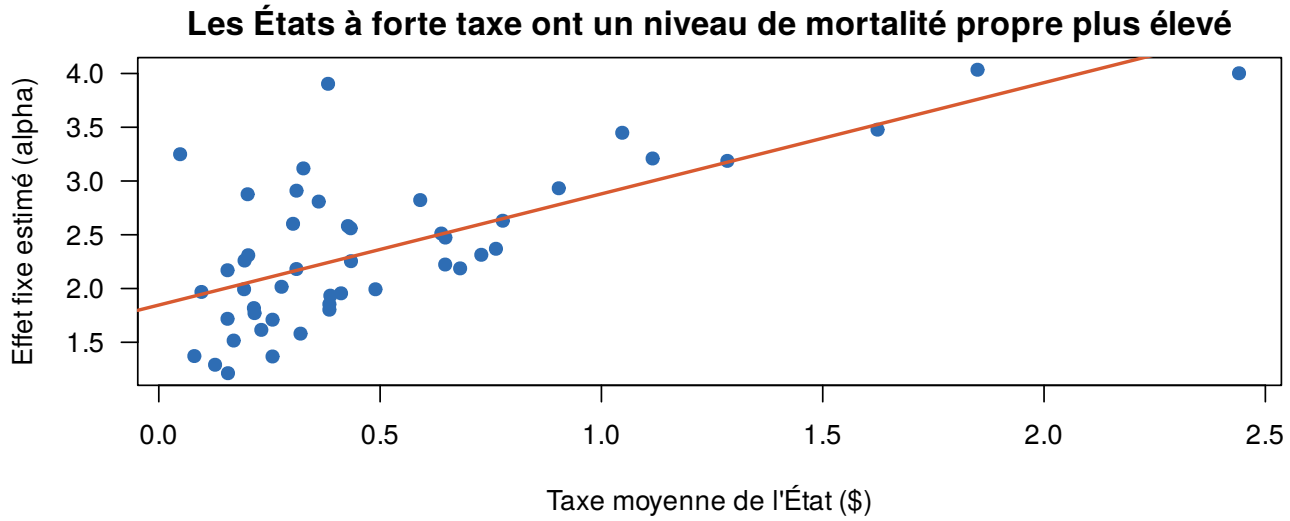
```
##       effet_1_dollar.beertax       en_pct_moyenne.beertax
##                  -0.65587372                  -32.14368007
## effet_hausse_typique.beertax  morts_evites_par_an.beertax
##                  -0.03621753                 7987.49422979
```

Lecture.

- Une hausse de la taxe de **1 dollar par caisse** est associée à **-0.66 mort pour 10 000 habitants** en moins, soit environ **32 %** du taux moyen. C'est un effet **important**.
- Mais 1 dollar est une hausse énorme par rapport aux variations observées : dans un même État, la taxe ne varie typiquement que de 0.055 dollar. Une hausse « réaliste » de 0,50 dollar dans tous les États correspondrait à environ **7 987 morts évités par an**. C'est un ordre de grandeur, pas une prévision.
- L'écart-type par grappe est assez grand (le coefficient n'est significatif qu'au seuil de 5 %), ce qui est logique : on n'utilise que la petite part de variation de la taxe qui se produit dans le temps.

6.4 Les effets propres aux États

```r
a <- fixef(m_fe)                                          # les 48 constantes
 ↪  alpha_i estimées
par(mar = c(4, 4.2, 2, 1), las = 1)
plot(tapply(F$beertax, F$state, mean)[names(a)], a, pch = 19, col = "#2E6DB4",
     xlab = "Taxe moyenne de l'État ($)", ylab = "Effet fixe estimé (alpha)",
     main = "Les États à forte taxe ont un niveau de mortalité propre plus élevé")
abline(lm(a ~ tapply(F$beertax, F$state, mean)[names(a)]), col = "#D85A30", lwd = 2)
 ↪  # tendance
```



Lecture. Les effets fixes $\hat{\alpha}_i$ sont **positivement liés à la taxe moyenne** : les États à forte taxe ont, pour d'autres raisons, une mortalité structurellement plus élevée. C'est **la preuve visuelle** du biais des MCO empilés, et la raison pour laquelle il fallait des effets fixes.

6.5 Faut-il des effets individuels ? Le test de Fisher

```
pFtest(m_fe, m_pool)        # H0 : toutes les constantes d'État sont égales (MCO
 ↪  empilés suffisants)
```

```
##
##  F test for individual effects
##
## data:  fr ~ beertax
## F = 52.179, df1 = 47, df2 = 287, p-value < 2.2e-16
## alternative hypothesis: significant effects
```

La p-valeur est quasi nulle, donc **on rejette** H_0 : les États ont des niveaux propres très différents, et les MCO empilés ne conviennent pas.

7 Ajouter des effets temporels (deux dimensions)

Notion. Certains chocs touchent **tous les États la même année** : voitures plus sûres, campagnes nationales, prix de l'essence. On les capte par un effet par année λ_t :

$$\text{fr}_{it} = \alpha_i + \lambda_t + \beta\,\text{taxe}_{it} + \varepsilon_{it}.$$

```
m_tw <- plm(fr ~ beertax, data = p, model = "within", effect = "twoways")   # effets
 ↪  États + années
coeftest(m_tw, vcov = vcovHC(m_tw, cluster = "group", type = "HC1"))       # robustes
 ↪  par État
```

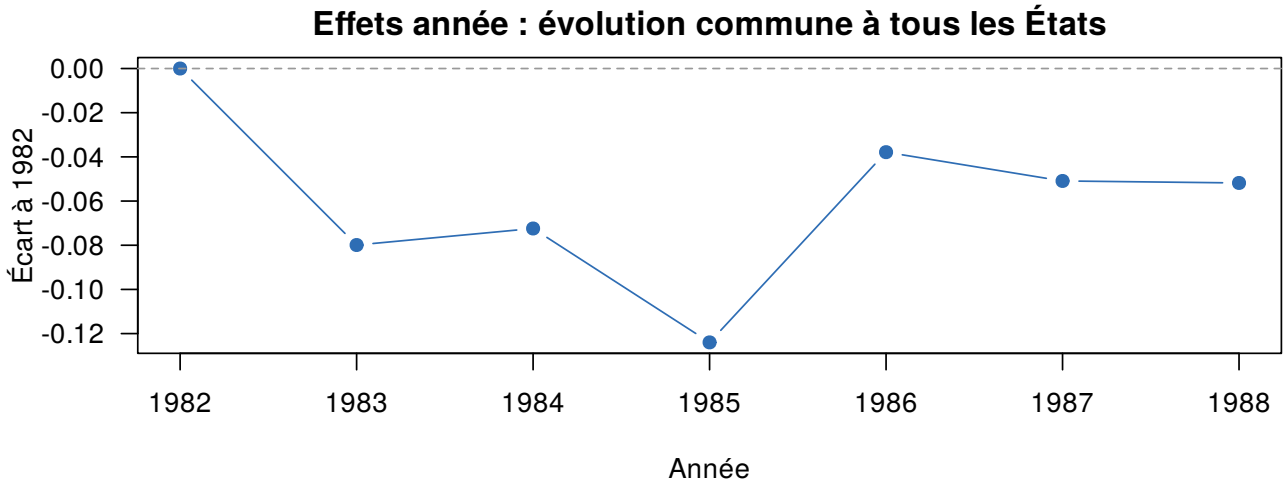
```
##
## t test of coefficients:
##
##         Estimate Std. Error t value Pr(>|t|)
## beertax -0.63998    0.35015 -1.8277  0.06865 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
pFtest(m_tw, m_fe)                                                          # H0 : pas
 ↪  d'effet année
```

```
##
##  F test for twoways effects
##
## data:  fr ~ beertax
## F = 2.0117, df1 = 6, df2 = 281, p-value = 0.0642
## alternative hypothesis: significant effects
```

```
lt <- fixef(m_tw, effect = "time")                    # effets année estimés
 ↪  (lambda_t)
par(mar = c(4, 4.2, 2, 1), las = 1)
plot(1982:1988, lt - lt[1], type = "b", pch = 19, col = "#2E6DB4", xlab = "Année",
     ylab = "Écart à 1982", main = "Effets année : évolution commune à tous les
      ↪  États")
```

```r
abline(h = 0, lty = 2, col = "grey60")                    # référence 1982
```



Lecture. Le coefficient de la taxe reste proche (-0.64) : l'effet n'est pas dû à une tendance nationale. Les effets année montrent la **baisse commune** de la mortalité. La p-valeur du test sur les effets année est à la limite du seuil de 5 % (0.064). On les garde par prudence : ils coûtent peu et protègent contre les chocs communs.

8 Effets aléatoires : un modèle concurrent

Notion. Le modèle à effets aléatoires traite l'effet de l'État comme une variable aléatoire u_i, **supposée non corrélée à la taxe**. Il utilise à la fois la variation « entre » et « dans ».

```r
m_re <- plm(fr ~ beertax, data = p, model = "random")          # effets aléatoires
 ↪  (MCG, Swamy-Arora)
coeftest(m_re, vcov = vcovHC(m_re, cluster = "group", type = "HC1"))
```

```
##
## t test of coefficients:
##
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  2.067141   0.120138 17.2065   <2e-16 ***
## beertax     -0.052016   0.109340 -0.4757   0.6346
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```r
m_re$ercomp$theta                                              # degré de centrage
 ↪  theta (0 = empilés, 1 = effets fixes)
```

```
##       id
## 0.862201
```

```r
plmtest(m_pool, type = "bp")                                   # Breusch-Pagan : H0 =
 ↪  pas d'effet aléatoire
```

```
##
##  Lagrange Multiplier Test - (Breusch-Pagan)
##
```

```
## data:  fr ~ beertax
## chisq = 754.57, df = 1, p-value < 2.2e-16
## alternative hypothesis: significant effects
```

Lecture. Les effets aléatoires donnent un coefficient presque nul (-0.052), car ils mélangent la variation « entre » (biaisée vers le haut) et la variation « dans ». Le test de Breusch-Pagan confirme qu'il existe des effets individuels. **Mais sont-ils corrélés à la taxe ?** C'est le test de Hausman qui le dit.

8.1 Le test de Hausman : effets fixes ou aléatoires ?

```
phtest(m_fe, m_re)      # H0 : effets individuels non corrélés à la taxe (EA
 ↪  convergent et efficace)
```

```
##
##  Hausman Test
##
## data:  fr ~ beertax
## chisq = 18.353, df = 1, p-value = 1.835e-05
## alternative hypothesis: one model is inconsistent
```

Lecture. $p = 1.8 \times 10^{-5}$: **on rejette** H_0. Les effets propres aux États sont **corrélés à la taxe**, ce qui rend les effets aléatoires biaisés. **On retient les effets fixes.** C'est exactement ce que suggérait la figure des $\hat{\alpha}_i$.

9 Ajouter des variables de contrôle

Pourquoi ? Les effets fixes éliminent ce qui est **stable** dans chaque État. Ce qui **change dans le temps** et peut être lié à la taxe peut encore biaiser le résultat, par exemple la conjoncture économique (on roule plus quand l'économie va bien) ou d'autres lois sur l'alcool au volant votées en même temps. On ajoute ces variables :

```
F$drinkagec <- cut(F$drinkage, breaks = c(18, 19, 20, 21, 22), right = FALSE)   # âge
 ↪  légal en classes (18 = référence)
p <- pdata.frame(F, index = c("state", "year"))                                  # on
 ↪  redéclare le panel avec la nouvelle variable
m_ctrl <- plm(fr ~ beertax + drinkagec + jail + service + miles + unemp + log(income),
              data = p, model = "within", effect = "twoways")                     #
               ↪  effets États + années + contrôles
coeftest(m_ctrl, vcov = vcovHC(m_ctrl, cluster = "group", type = "HC1"))         #
 ↪  écarts-types robustes par État
```

```
##
## t test of coefficients:
##
##                     Estimate  Std. Error t value  Pr(>|t|)
## beertax          -4.4895e-01  2.9245e-01 -1.5351  0.125913
## drinkagec[19,20) -4.6699e-02  5.7777e-02 -0.8083  0.419650
## drinkagec[20,21)  3.2268e-03  6.6105e-02  0.0488  0.961104
## drinkagec[21,22) -2.8149e-02  6.8947e-02 -0.4083  0.683398
## jailyes           1.3058e-02  1.6336e-02  0.7994  0.424772
## serviceyes        3.3446e-02  1.3049e-01  0.2563  0.797906
```

```
## miles             8.2275e-06  6.7222e-06  1.2239  0.222041
## unemp            -6.3111e-02  1.2788e-02 -4.9352 1.398e-06 ***
## log(income)       1.8146e+00  6.2504e-01  2.9031  0.003998 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
pdim(m_ctrl)$nT$n                                                    #
 ↪  nombre d'observations utilisées
```

```
## [1] 48
```

Lecture.

- La **taxe** garde un coefficient négatif (-0.45), mais il n'est **plus significatif**. Une partie de son effet apparent passait par la conjoncture. Le signe reste négatif, mais la preuve d'un effet propre de la taxe devient fragile.
- Le **chômage** a un effet négatif très significatif, et le **revenu** un effet positif : quand l'économie va bien, on roule plus, et il y a plus d'accidents. Ce sont des facteurs qui changent dans le temps et que les effets fixes seuls ne captaient pas.
- L'**âge légal** et les **peines** (prison, travaux d'intérêt général) n'ont **pas d'effet significatif** dans ce modèle.
- Une observation manquante (Californie 1988, variables `jail` et `service`) est retirée : le panel devient légèrement non cylindré, ce que `plm` gère sans difficulté.

9.1 Tableau récapitulatif des modèles

```
se <- function(m) sqrt(diag(vcovHC(m, cluster = "group", type = "HC1")))["beertax"]
 ↪  # écart-type robuste de la taxe
recap <- data.frame(
  Modele = c("Coupe 1982", "Coupe 1988", "MCO empilés", "Avant-après 1982-88", "Effets
   ↪  fixes États",
             "Effets fixes États + années", "Effets aléatoires", "Deux dimensions +
              ↪  contrôles"),
  coef_taxe = c(coef(c82)[2], coef(c88)[2], coef(m_pool)[2], coef(m_diff)[2],
   ↪  coef(m_fe), coef(m_tw),
                coef(m_re)[2], coef(m_ctrl)["beertax"]),
  ecart_type = c(sqrt(vcovHC(c82, type = "HC1")[2, 2]), sqrt(vcovHC(c88, type =
   ↪  "HC1")[2, 2]), se(m_pool),
                 sqrt(vcovHC(m_diff, type = "HC1")[2, 2]), se(m_fe), se(m_tw),
                  ↪  se(m_re), se(m_ctrl)))
recap$t <- recap$coef_taxe / recap$ecart_type                    # statistique t
knitr::kable(recap, digits = 3, caption = "Coefficient de la taxe sur la bière selon
 ↪  le modèle (écarts-types robustes).")
```

Tableau 2: Coefficient de la taxe sur la bière selon le modèle (écarts-types robustes).

Modele	coef_taxe	ecart_type	t
Coupe 1982	0.148	0.133	1.120
Coupe 1988	0.439	0.128	3.431

Modele	coef_taxe	ecart_type	t
MCO empilés	0.365	0.119	3.074
Avant–après 1982-88	-1.041	0.355	-2.932
Effets fixes États	-0.656	0.289	-2.271
Effets fixes États + années	-0.640	0.350	-1.828
Effets aléatoires	-0.052	0.109	-0.476
Deux dimensions + contrôles	-0.449	0.292	-1.535

Lecture d'ensemble. Les modèles qui comparent les États **entre eux** (coupes, MCO empilés) trouvent un effet **positif**, donc absurde. Ceux qui comparent chaque État **à lui-même** (avant–après, effets fixes) trouvent un effet **négatif**, d'environ $-0{,}65$. Avec les contrôles économiques, l'effet reste négatif mais devient imprécis.

10 Diagnostics : les écarts-types sont-ils fiables ?

```
pwartest(fr ~ beertax, data = p)                    # Wooldridge : H0 = pas
 ↪  d'autocorrélation des erreurs (effets fixes)
```

```
##
##  Wooldridge's test for serial correlation in FE panels
##
## data:  plm.model
## F = 69.465, df1 = 1, df2 = 286, p-value = 3.299e-15
## alternative hypothesis: serial correlation
```

```
pcdtest(m_tw, test = "cd")                          # Pesaran CD : H0 = pas de
 ↪  dépendance entre États
```

```
##
##  Pesaran CD test for cross-sectional dependence in panels
##
## data:  fr ~ beertax
## z = 1.1956, p-value = 0.2318
## alternative hypothesis: cross-sectional dependence
```

```
c(usuel = coef(summary(m_fe))["beertax", 2],        # écart-type usuel du modèle à
 ↪  effets fixes
  robuste_grappe = se(m_fe))                        # écart-type robuste par État
```

```
##                  usuel robuste_grappe.beertax
##              0.1878500              0.2887982
```

Lecture.

- Le test de Wooldridge détecte une **autocorrélation** des erreurs au sein des États : les chocs persistent d'une année sur l'autre.
- L'écart-type robuste par grappe est **nettement plus grand** que l'écart-type usuel. Avec l'écart-type usuel, on aurait surestimé la précision de l'effet. C'est pourquoi on a utilisé des écarts-types par grappe partout.
- Le test de Pesaran (p = 0.23) ne détecte pas de dépendance entre États une fois les effets année inclus : les écarts-types par grappe suffisent. Si cette dépendance avait été forte, on aurait utilisé des écarts-types de Driscoll-Kraay (`vcovSCC`).

11 Bonus : le même problème vu comme un modèle mixte

Notion. En biostatistique, on écrirait un **modèle mixte** avec un intercept aléatoire par État. C'est l'équivalent des effets aléatoires, avec la même hypothèse d'absence de corrélation avec la taxe.

```
m_mix <- lmer(fr ~ beertax + year + (1 | state), data = F, REML = TRUE)   # intercept
 ↪  aléatoire État + effets année fixes
fixef(m_mix)["beertax"]                                  # coefficient de la taxe
```

```
##     beertax
## -0.04740393
```

```r
vc <- as.data.frame(VarCorr(m_mix))                    # composantes de variance
icc <- vc$vcov[1] / sum(vc$vcov)                       # ICC : part de la variance
 ↪  due aux États
icc
```

```
## [1] 0.8937012
```

Lecture. L'ICC vaut **0.89** : environ 89 % de la variance de la mortalité (à année donnée) vient de **différences permanentes entre États**. Le coefficient de la taxe dans le modèle mixte (-0.05) est proche de celui des effets aléatoires, et il est **biaisé pour la même raison** (le test de Hausman l'a montré). Le modèle mixte reste utile pour **décrire** cette variabilité entre États. Pour la question **causale**, on garde les effets fixes.

12 Conclusion, limites et préparation de l'entretien

12.1 Ce que montre le projet

1. Comparer des États entre eux conduit à une conclusion **absurde** : la taxe augmenterait la mortalité. La cause est l'**hétérogénéité non observée** entre États.
2. En comparant chaque État **à lui-même** (effets fixes), on obtient l'effet attendu : **−0,66 mort pour 10 000 habitants par dollar de taxe**, robuste aux effets année.
3. Le test de **Hausman** rejette les effets aléatoires : les effets propres aux États sont corrélés à la taxe.
4. Avec les contrôles économiques, l'effet reste **négatif** mais devient **non significatif**. La preuve d'un effet propre de la taxe est donc **suggestive, pas définitive**.

12.2 Limites

- La taxe **varie peu** dans le temps au sein d'un État : les estimations sont imprécises.
- Les effets fixes n'éliminent que les facteurs **stables**. Une loi ou une campagne locale votée en même temps qu'une hausse de taxe pourrait encore biaiser le résultat.
- La période est courte (7 ans) et ancienne (1982-1988).
- La mortalité est un **taux construit à partir de comptages**. Un modèle de Poisson à effets fixes, avec la population en *offset*, serait une extension naturelle.

12.3 Phrase possible pour une lettre de motivation

> Dans un travail personnel sur données de panel (48 États américains, 1982-1988), j'ai évalué l'effet des taxes sur l'alcool sur la mortalité routière : j'ai montré que des modèles à effets fixes, choisis par un test de Hausman et estimés avec des écarts-types robustes par grappe, corrigeaient un biais d'hétérogénéité non observée qui inversait le signe de l'effet.

12.4 Questions probables en entretien

Question	Réponse courte
Pourquoi la régression simple trouve-t-elle un effet positif ?	Biais de variable omise : les États à forte taxe ont, pour d'autres raisons, une mortalité structurellement élevée.

Question	Réponse courte
Que font les effets fixes ?	Ils comparent chaque État à lui-même dans le temps, ce qui élimine tout ce qui est propre à l'État et stable.
Pourquoi pas des effets aléatoires ?	Le test de Hausman rejette (p 2×10) : les effets propres aux États sont corrélés à la taxe.
Pourquoi des écarts-types par grappe ?	Les erreurs d'un même État sont autocorrélées (test de Wooldridge) ; les écarts-types usuels sous-estiment l'incertitude.
Que devient l'effet avec des contrôles ?	Il reste négatif ($-0{,}45$) mais n'est plus significatif : la conjoncture explique une partie de l'effet apparent.
Quelle limite principale ?	Peu de variation de la taxe dans le temps, et des facteurs variables dans le temps non contrôlés.

12.5 Pour aller plus loin

- Un **Poisson à effets fixes** (`fixest::fepois`) sur les nombres de morts, avec la population en *offset*.
- Une **analyse par tranche d'âge** (variables `fatal1820`, `fatal2124`) : les jeunes conducteurs réagissent-ils plus à la taxe ?
- Un **événement** (*event study*) autour des changements d'âge légal pour boire.